

Примечание

Конспект подготовлен для ознакомления с материалами курса «Байесовские методы в анализе данных» 2026. Конспект опирается на лекции курса «Байесовские методы в машинном обучении». Конспект может содержать опечатки и неточности. Актуальный [GitHub](#).

Содержание

Лекция 1. Байесовский подход к теории вероятностей	2
1.1 Основные понятия	2
1.2 Частотный и байесовский подходы	4
1.3 Приятные плюсы байесовского подхода	6
1.4 Сопряжённые распределения	6

Лекция 1. Байесовский подход к теории вероятностей

В этой лекции мы разберём, что такое байесовские методы и чем они отличаются от обычных статистических методов.

1.1 Основные понятия

Машинное обучение является областью математики, которая занимается поиском взаимозависимостей в данных. На вероятностном языке взаимозависимость между величинами можно выразить через условное распределение.

Определение 1. Пусть x и y — две случайные величины. Тогда условным распределением $p(x|y)$ (conditional distribution) x относительно y называется отношение совместного распределения $p(x, y)$ (joint distribution) и маргинального распределения $p(x)$ (marginal distribution, оно же безусловное):¹

$$p(x|y) = \frac{p(x, y)}{p(y)}. \quad (1)$$

Смысл этого определения в следующем: условное распределение показывает то, как ведет себя x , если мы уже пронаблюдали y . Заметим, что если величины x и y независимы, т.е. $p(x, y) = p(x)p(y)$, то $p(x|y) = p(x)$. Что означает, что никакой информации об x в y не содержится.

Далее из формулы (1), совместное распределение можно выразить через условное и маргинальное:

$$p(x, y) = p(x|y)p(y). \quad (2)$$

Такое равенство называют *правилом произведения* (product rule). Рассуждая по индукции, несложно прийти к его обобщению на n случайных величин:

Теорема 1 (Правило произведения). Пусть $x_1, \dots, x_n$ — случайные величины. Тогда их совместное распределение можно представить в виде произведения n одномерных условных распределений с постепенно уменьшающейся посылкой:

$$p(x_1, \dots, x_n) = p(x_n | x_1, \dots, x_{n-1}) \cdots p(x_2 | x_1) p(x_1) = p(x_1) \prod_{k=2}^n p(x_k | x_1, \dots, x_{k-1}). \quad (3)$$

В дальнейшем мы часто будем сталкиваться с вероятностными моделями машинного обучения, в которых нужно уметь задавать совместное распределение на все величины, фигурирующие в модели. Работать с одним многомерным распределением, вообще говоря, гораздо сложнее, чем с несколькими одномерными, поэтому для вероятностных моделей машинного обучения совместное распределение очень часто вводится через рассмотренную выше декомпозицию.

Заметим, что при декомпозиции не играет роли порядок выбора величин, для которых мы выписываем условное распределение

$$p(x|y)p(y) = p(x, y) = p(y|x)p(x). \quad (4)$$

Обобщая это на случай n величин, получаем, что в (3) тоже не важен порядок выбора случайных величин $x_1, \dots, x_n$ — декомпозиция всё равно будет верна.

Из равенства (4) сразу же получается *правило обращения условной вероятности*:

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)}. \quad (5)$$

¹Стоит заметить, что когда пишут $p(x)$, обычно подразумевают плотность в смысле математической статистики. Если случайная величина x дискретна, то $p(x)$ равна вероятности того, что она будет равна какому-то числу x . Если же рассматривается абсолютно непрерывная случайная величина, то $p(x)$ есть плотность в обычном смысле в точке x . Данное обозначение первоначально может казаться очень непривычным, но со временем оно станет интуитивно понятным.

Теперь проинтегрируем обе части равенства (5) по y .² Заметим, что слева получится единица, так как интегрируется плотность распределения. Тем самым получаем, что

$$1 = \frac{\int p(x|y)p(y)dy}{p(x)} \Rightarrow p(x) = \int p(x|y)p(y)dy = \int p(x,y)dy. \quad (6)$$

Данное тождество носит название *правила суммирования* (sum rule). Оно показывает, как перейти от совместного распределения к маргинальному или же совместному на какое-то подмножество величин: просто интегрируем по всем остальным переменным. Этот процесс называют выинтегрированием (integrate out) или *маргинализацией*. Поэтому полученное после интегрирования распределение называется маргинальным. Так же, как и с правилом произведения, правило суммирования обобщается по индукции:

Теорема 2 (Правило суммирования). Пусть $x_1, \dots, x_n$ — случайные величины. Если известно их совместное распределение $p(x_1, \dots, x_n)$, то совместное распределение подмножества случайных величин $x_1, \dots, x_k$ будет равно

$$p(x_1, \dots, x_k) = \int p(x_1, \dots, x_n) dx_{k+1} \dots dx_n. \quad (7)$$

Теперь посмотрим внимательнее на равенство (6). Можно заметить, что правило суммирования есть не что иное как взятие математического ожидания:

$$p(x) = \int p(x|y)p(y)dy = \mathbb{E}_y[p(x|y)].$$

Таким образом, если мы умеем считать $p(x|y)$ при всех возможных y , а хотим знать $p(x)$, то нам нужно просто усреднить $p(x|y)$ по всем y .

Из правила обращения условной вероятности (5) и правила суммирования (6) получаем широко известную теорему:

Теорема 3 (Байес). Пусть x и y — случайные величины. Тогда

$$p(y|x) = \frac{p(x|y)p(y)}{\int p(x|y)p(y)dy}. \quad (8)$$

В концептуальной форме это правило звучит так: *апостериорное распределение* $p(y|x)$ (posterior distribution) с точностью до нормировочной константы равно произведению *правдоподобия* $p(x|y)$ (likelihood) и *априорного распределения* $p(y)$ (prior distribution). Нормировочную константу обычно называют *обоснованностью* (evidence).

Какой смысл у теоремы Байеса? На самом деле это достаточно простое и элегантное правило, позволяющее уточнять наше незнание о некоей величине при поступлении новой информации, косвенно связанной с ней. Пусть $p(y)$ — распределение, которое показывает нашу неопределённость относительно значения y . Теорема Байеса показывает, как наша неопределённость изменилась после наблюдения x (одного или нескольких), который как-то связан с y — то, как именно он связан, задаётся функцией правдоподобия.³

Теорема Байеса является частным случаем того, как можно решать обратные задачи: если мы знаем как x влияет на y , то теорема Байеса дает нам возможность узнать, как y влияет на x .

Заметим следующее полезное применение теоремы Байеса. Если задана вероятностная модель (совместное распределение на все переменные), то можно посчитать любое⁴ условное распределение. Например, скажем, что на три группы случайных величин x , y и z задана нефакторизуемая вероятностная модель $p(x, y, z)$. Как посчитать $p(x|y)$? Достаточно просто:

$$p(x|y) = \frac{p(x,y)}{p(y)} = \frac{\int p(x,y,z)dz}{\iint p(x,y,z)dx dz}. \quad (9)$$

²Если распределение дискретное, то мысленно заменяйте интеграл на сумму — ситуация не изменится.

³Из этой интерпретации и следуют названия распределений: априорное — до эксперимента, апостериорное — после.

⁴На самом деле утверждение о том, что можно посчитать любое условное распределение, верно только в теории: на практике всё упирается в то, получится ли посчитать интегралы.

1.2 Частотный и байесовский подходы

В рамках классических курсов изучался подход, который в англоязычной литературе называют *частотным* или *фреквентистским* (frequentist). Вспомним, как в нём решается следующая задача: оценка параметров распределения по выборке из него. Скажем, что есть выборка $X = (x_1, \dots, x_n)$ из параметрического распределения $p_\theta(x)$. Заметим, что такое распределение вполне можно писать как $p(x|\theta)$, т.е. рассматривать параметры θ как случайные величины, — смысл от этого не меняется. Чтобы оценить параметры θ , в классическом частотном подходе используется метод максимального правдоподобия⁵:

$$\theta_{\text{ML}} = \arg \max_{\theta} p(X|\theta) = \arg \max_{\theta} \prod_{i=1}^n p(x_i|\theta) = \arg \max_{\theta} \sum_{i=1}^n \log p(x_i|\theta). \quad (10)$$

Во многих частных случаях сумма логарифмов правдоподобий будет выпуклой вверх функцией, то есть у неё один максимум, который достаточно легко найти даже в пространствах высокой размерности. Заметим, что θ_{ML} — случайная величина, поскольку она является функцией от выборки.

Оценка максимума правдоподобия (ОМП) обладает очень хорошими свойствами:

- Состоятельность: ОМП сходится к истинному значению параметров по вероятности при $n \rightarrow +\infty$ (где n — размер выборки)
- Асимптотическая несмещенность: $\theta_{\text{ML}} = \mathbb{E}[\theta]$ при $n \rightarrow +\infty$
- Асимптотическая нормальность: θ_{ML} распределена нормально при $n \rightarrow +\infty$
- Асимптотическая эффективность: ОМП обладает наименьшей дисперсией среди всех состоятельных асимптотически нормальных оценок.

Поэтому часто говорят, что лучше ОМП ничего придумать нельзя. Но если всё так хорошо, то зачем вообще нужны другие подходы?

На самом деле всё не так просто. Что мы делаем при оценке максимального правдоподобия? Мы пытаемся найти такие параметры, чтобы вероятность пронаблюдать то, что мы пронаблюдали, была максимальной. Говоря на языке машинного обучения, мы подстраиваем параметры под обучающую выборку. Но мы знаем, что прямая подгонка под данные часто черевата переобучением.

Давайте поймём, какую альтернативу нам дает применение теоремы Байеса. Пусть у нас есть априорное распределение $p(\theta)$, которое отражает некую внешнюю информацию о возможных значениях параметров (если такой информации нет, мы всегда можем ввести неинформативное распределение). Тогда результатом применения теоремы Байеса будет апостериорное распределение на параметры:

$$p(\theta|X) = \frac{\prod_{i=1}^n p(x_i|\theta) \cdot p(\theta)}{\int \prod_{i=1}^n p(x_i|\theta) \cdot p(\theta) d\theta} \quad (11)$$

Обратите внимание, что теперь ответом является новое распределение на параметры модели, в отличие от метода максимального правдоподобия, где ответом являлось конкретное значение параметров. Сильной стороной данного подхода является то, что при получении апостериорного распределения мы не теряем ни бита информации, которая содержалась в обучающей выборке. В случае же ОМП масса информации теряется (смысл этого утверждения будет показан далее на примерах).

Изобразим таблицу, которая будет показывать различия частотного (классического) и байесовского подходов (см. таблицу 1). Первое и основное отличие состоит в том, как вообще понимать случайность. В частотном подходе предполагается, что случайная величина — это результат некоторого процесса, для которого принципиально невозможно предсказать исход (объективная неопределенность, т.е. у всех одинаковая). В байесовском подходе считается, что процесс на самом деле детерминированный, но часть факторов, которые влияют на этот процесс, неизвестны наблюдателю (субъективное незнание, т.е. у всех разное).

Рассмотрим примеры субъективного незнания.

⁵Напомним, что $p(X|\theta)$ — условное распределение на X — называется правдоподобием, если мы рассматриваем его как функцию параметров θ

	Частотный подход	Байесовский подход
Интерпретация случайности	Объективная неопределённость	Субъективное незнание
Виды величин	Случайные и детерминированные	Все величины можно интерпретировать как случайные
Метод вывода	Метод максимального правдоподобия	Теорема Байеса
Виды оценок	Точечная оценка	Апостериорное распределение
Применимость	$n \gg d$	Любое $n \geq 0$

Таблица 1: Отличия частотного и байесовского подходов (n — количество элементов в выборке, d — число параметров)

Пример. Допустим, что мы подбрасываем монетку и смотрим, что выпало. В классической теории вероятностей мы привыкли считать, что исход данного эксперимента является объективной неопределённостью, т.е. случайным в частотном смысле. Однако если бы нам были известны все условия эксперимента (переданный импульс, масса монетки, сопротивление воздуха и так далее), то можно было бы с помощью уравнений классической механики точно рассчитать какой стороной упадёт монетка. Мы не можем этого сделать только потому, что нам неизвестны все факторы, влияющие на движение монетки. Таким образом, результат эксперимента является случайной величиной в байесовском смысле.

Пример. Пусть мы каждый день пользуемся автобусом, который по расписанию приходит на остановку в 10:30. Однако в реальности день ото дня автобус то задерживается, то опаздывает, т.е. время его прихода является случайной величиной. Хотя мы не можем сказать, что это объективная неопределённость, так как на время прибытия автобуса в жизни влияет конечный набор факторов (светофоры, пешеходы на переходах и т.д.). И в зависимости от знания этих факторов мы можем точно предсказать время прибытия автобуса. Т.е. это время является случайной величиной в байесовском смысле. Также можно заметить, что в зависимости от степени субъективного незнания наблюдатель может предсказать время прибытия с разной точностью. Например, мы, исходя из наших ежедневных наблюдений, можем сказать, что среднее отклонение от расписания у автобуса ± 7 минут. А наш товарищ пользуется программой, которая отображает в реальном времени положение автобуса. И он может предсказывать время прибытия с точностью ± 3 минуты. Таким образом, с точки зрения обоих наблюдателей время прихода автобуса — случайная величина, но степень субъективного незнания о ней у них разная.

Стоит заметить, что в реальности существуют примеры объективных неопределённостей — это процессы, являющиеся результатом квантово-механических эффектов (например, распады радиоактивных ядер).

Перейдем к видам величин. В байесовском подходе вообще все величины можно считать случайными. Все параметры модели, которые мы не знаем, мы считаем случайными и задаем на них априорные распределения. А если параметр нам известен, то мы можем задать его распределение дельта-функцией и продолжать считать его случайной величиной. В частотном же подходе параметры распределения считаются неизвестными детерминированными величинами. Отсюда вытекает отличие в методе оценивания параметров модели: в байесовском подходе мы уменьшаем наше незнание, получая апостериорное распределение по формуле Байеса, а в частотном — находим конкретные значения параметров с помощью ОМП.

Последнее отличие состоит в том, когда какой подход можно применять. У метода максимального правдоподобия есть одна проблема: все его свойства асимптотические, то есть они выполняются при $n \rightarrow +\infty$. В байесовском подходе такого ограничения нет: выводы

можно делать при любом $n \geq 0$.⁶

Таким образом, при малых значениях n гарантии на ОМП не выполняются, и лучше работает байесовский подход. А какой метод лучше применять при больших n ? Оказывается, что при больших размерах выборки один подход переходит в другой: можно показать, что при $n \rightarrow +\infty$ апостериорное распределение коллапсирует в дельта-функцию в точке максимума правдоподобия. Поэтому можно не мучиться с байесовским выводом апостериорных распределений и применять частотный подход.

Тут у самых вѣдливых читателей должен возникнуть вопрос, а зачем мы в век больших данных вообще рассуждаем про малые выборки? Строго говоря, мы должны сделать оговорку, что размер выборки мы должны сравнивать с числом параметров модели. И вот если $n/d \rightarrow \infty$ то мы можем использовать ОМП. Но в современных нейросетях часто возникает ситуация, когда $n/d \ll 1$, что ставит под сомнение корректность применения метода максимального правдоподобия.

1.3 Приятные плюсы байесовского подхода

1. Регуляризация: за счёт введения априорного распределения на параметры получается так, что они не слишком «подгоняются» под данные.
2. Композитность: есть возможность постепенно улучшать предсказание на параметры, если предыдущий результат вывода считать априорным распределением при поступлении новых данных. Действительно, если x — имеющиеся данные, y — оцениваемый параметр, а z — это другие данные (предполагается, что они не зависят от x), то

$$p(y | x, z) = \frac{p(z | y)p(y | x)}{\int p(z | y)p(y | x)dy}. \quad (12)$$

3. Обработка данных «на лету»: нет необходимости хранить все данные для построения прогноза — достаточно хранить апостериорное распределение и постепенно его пересчитывать: оно будет хранить в себе информацию из всех данных.
4. Построение моделей с скрытыми (латентными) переменными: возможность корректно обрабатывать пропуски в данных (об этом будет рассказано позднее).
5. Масштабируемость: в некоторых случаях байесовский подход переносится на большие данные, при этом оставаясь вычислительно эффективным. Это свойство подробнее будет описываться на курсе нейробайесовских методов.

Тем самым в байесовском подходе можно сделать то, чего нельзя сделать в булевой логике.

1.4 Сопряжённые распределения

Пусть нам дана выборка из некоторого параметрического семейства $X = \{x_i\}_{i=1}^n$, $x_i \sim p(x | \theta)$, и у нас есть некоторое априорное распределение на параметры $p(\theta)$. Тогда, пользуясь формулой Байеса, мы можем найти апостериорное распределение на θ при условии того, что мы пронаблюдали X .

$$p(\theta | X) = \frac{p(X | \theta)p(\theta)}{\int p(X | \theta)p(\theta)d\theta} \quad (13)$$

К сожалению, интеграл в числителе берется аналитически в очень редких случаях. Поэтому в дальнейших лекциях курса мы много будем говорить о различных способах оценки апостериорного распределения.

Однако, давайте подумаем, что мы можем сделать, не зная значение интеграла. Например, вполне несложно найти максимум апостериорного распределения. Действительно:

⁶Формально их можно сделать даже при $n = 0$ — в таком случае оценкой будет выступать априорное распределение.




Рис. 1: Пример распределения, у которого мода нерепрезентативна.

$$\theta_{MP} = \arg \max_{\theta} p(\theta | X) = \arg \max_{\theta} p(X | \theta)p(\theta) = \quad (14)$$

$$= \arg \max_{\theta} \left(\prod_{i=1}^n p(x_i | \theta)p(\theta) \right) = \arg \max_{\theta} \left(\sum_{i=1}^n \ln p(x_i | \theta) + \ln p(\theta) \right) \quad (15)$$

Получили довольно известную регуляризацию на давно знакомую оценку максимального правдоподобия. Так, например, если в качестве априорного распределения мы возьмём нормальное распределение с нулевым математическим ожиданием и некоторой дисперсией λ^{-1} , регуляризация превратится в $\lambda \|\theta\|^2$, то есть L2-регуляризацию.

Однако, хоть мы и получили в каком-то смысле неплохую точечную оценку на θ , у такого метода есть ряд минусов:

- **Нет оценки неопределённости.** Зачастую в прикладных задачах нам важно не только получить ответ на вопрос, но и понимать, насколько мы в нём уверены. Если у нас есть апостериорное распределение, мы можем построить доверительные интервалы на θ_{MP} , чтобы понимать, в каких пределах может меняться полученное значение. Точечная оценка не дает нам такой возможности.
- **Нет возможности объединения информации, полученной из различных источников.** Одним из плюсов байесовского подхода является то, что мы можем сложные вероятностные модели строить из простых, как из кирпичиков. Рассчитав апостериорное распределение при условии выборки из одного источника, мы можем подать его в качестве априорного распределения для расчета апостериорного распределения при условии выборки из другого источника. Таким образом, в итоговом апостериорном распределении будет содержаться вся информация от обоих источников. Если же у нас есть только точечная оценка на параметры модели, такого элегантного объединения информации из разных источников у нас сделать не получится.
- **Мода распределения может быть нерепрезентативна.** Пример такого распределения можно увидеть на Рисунке 1.

Метод замены апостериорного распределения его модой получил название “*Байес для бедных*” (“*Poor man’s Bayes*”), как довольно простой вычислительно, но имеющий весомые недостатки. Подробно изучать его мы не будем; предполагается, что он уже достаточно знаком из прочих курсов по машинному обучению. Нас же интересуют более эффективные и интересные подходы к байесовскому выводу.

Начнём с рассмотрения важного частного случая, когда интеграл аналитически вычислить всё-таки возможно: это случай *сопряжённых* семейств распределений.

Определение 2. Пусть функция правдоподобия и априорное распределение принадлежат некоторым параметрическим семействам распределений: $p(X | \theta) \sim \mathcal{A}(\theta)$ и $p(\theta | \beta) \sim \mathcal{B}(\beta)$. Семейства $\mathcal{A}$ и $\mathcal{B}$ являются сопряжёнными (conjugate) тогда и только тогда, когда $p(\theta | X) \sim \mathcal{B}(\beta')$.

Из этого определения следует, что если функция правдоподобия $p(X | \theta)$ и априорное распределение $p(\theta | \beta)$ сопряжены, то апостериорное распределение $p(\theta | X)$ лежит в том

же параметрическом семействе $\mathcal{B}(\beta')$, что и априорное $p(\theta | \beta)$. То есть, апостериорное распределение $p(\theta | x)$ можно вычислить аналитически. Рассмотрим несколько примеров:

1. Пусть функция правдоподобия $p(x | \mu) = \mathcal{N}(x | \mu, 1)$. Как будет выглядеть сопряженное ему $p(\mu)$?

$$p(x | \mu) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2}\right) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2} + x\mu - \frac{\mu^2}{2}\right) \quad (16)$$

Нужно подобрать такое $p(\mu)$, чтобы его функциональный вид не изменился при умножении на вышеприведённое выражение (“перевёрнутая парабола под экспонентой”). Легко заметить, что для этого нам подойдёт такой же вид:

$$p(\mu) = \frac{1}{\sqrt{2\pi}s} \exp\left(-\frac{\mu^2}{2s^2} + \frac{\mu m}{s^2} - \frac{m^2}{2s^2}\right) = \mathcal{N}(\mu | m, s^2) \quad (17)$$

Теперь проверим:

$$\begin{aligned} p(x | \mu)p(\mu) &= \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2} + x\mu - \frac{\mu^2}{2}\right) \cdot \frac{1}{\sqrt{2\pi}s^2} \exp\left(-\frac{\mu^2}{2s^2} + \frac{\mu m}{s^2} - \frac{m^2}{2s^2}\right) \propto \quad (18) \\ &\propto \exp\left(-\frac{\mu^2(s^2 + 1)}{2s^2} + \frac{\mu(m + xs^2)}{s^2} - \frac{x^2s^2 + m^2}{2s^2}\right) \propto \exp\left(-\frac{s^2 + 1}{2s^2} \left(\mu - \frac{m + xs^2}{s^2 + 1}\right)^2\right) \propto \quad (19) \end{aligned}$$

$$\propto \mathcal{N}\left(\mu \mid \frac{m + xs^2}{s^2 + 1}, \frac{s^2}{s^2 + 1}\right) \quad (20)$$

Действительно, получили аналитический вид для апостериорного распределения $p(\mu | X)$, и оказалось, что $p(\mu | X)$ тоже лежит в семействе нормальных распределений.

2. $p(x | \gamma) = \mathcal{N}(x | 0, \gamma^{-1})$; $p(\gamma)$ —?

$$p(x | \gamma) = \sqrt{\frac{\gamma}{2\pi}} \exp\left(-\frac{\gamma}{2}x^2\right)$$

Получили корень из γ , умноженный на экспоненту линейной функции. Вопрос: какой функциональный вид должно иметь априорное распределение?

$$p(\gamma) = \frac{\beta^\alpha}{\Gamma(\alpha)} \gamma^{\alpha-1} \exp(-\gamma\beta) \sim G(\gamma | \alpha, \beta)$$

3. $p(x | \mu, \gamma) \sim \mathcal{N}(x | \mu, \gamma^{-1})$; $p(\mu, \gamma)$ —?

Сразу хочется сослаться на два предыдущих пункта и записать $p(\mu, \gamma) = p(\mu)p(\gamma)$. Но действительно ли это выполняется?

$$p(x | \mu, \gamma) = \sqrt{\frac{\gamma}{2\pi}} \exp\left(-\frac{\gamma}{2}(x - \mu)^2\right) = \sqrt{\frac{\gamma}{2\pi}} \exp\left(-\frac{\gamma x^2}{2} + \gamma\mu x - \frac{\gamma\mu^2}{2}\right)$$

Заметим, что это выражение не факторизуется по μ и γ . Значит, и априорное распределение, если оно сопряжено, факторизоваться не может.

На самом деле сопряжённым распределением является так называемое *гамма-нормальное* распределение:

$$p(\mu, \gamma) = p(\mu | \gamma)p(\gamma) = \mathcal{N}(\mu | m, (\lambda\gamma)^{-1})G(\gamma | a, b)$$

Теперь посмотрим, как производить поиск сопряженных распределений не для каждого частного случая, а в некотором общем виде.