

Примечание

Конспект подготовлен для ознакомления с материалами курса «Байесовские методы в анализе данных» 2026. Конспект опирается на лекции курса «Байесовские методы в машинном обучении». Конспект может содержать опечатки и неточности. Актуальный [GitHub](#).

Содержание

Лекция 3. ЕМ-алгоритм и модели со скрытыми переменными	2
3.1 Экспоненциальный класс распределений	2
3.2 Проблемы в оптимизации правдоподобия	3
3.3 Вывод ЕМ-алгоритма	5
3.4 Обсуждение ЕМ-алгоритма и примеры	7
3.5 Восстановление разметки с помощью ЕМ-алгоритма (GLAD)	8

Лекция 3. ЕМ-алгоритм и модели со скрытыми переменными

Это ключевая лекция курса, в которой мы поймём как и зачем нужно строить модель со скрытыми (или латентными) переменными и какими методами можно такие модели обучать¹. В классическом курсе по машинному обучению ЕМ-алгоритм обычно рассматривается на примере разделения смеси гауссиан.

3.1 Экспоненциальный класс распределений

До этого мы с вами рассматривали параметрические распределения, подразумевая, что плотность нам известна с точностью до некоторого параметра θ . Такие множества распределений мы называли *параметрическими семействами*. Теперь мы перейдем к понятию *класса распределений*, который будем задавать с точностью до функционального вида.

Определение 1. Будем говорить, что распределение $p(x|\theta)$ лежит в экспоненциальном классе, если оно может быть представлено в следующем виде

$$p(x|\theta) = \frac{f(x)}{g(\theta)} \exp(\theta^T u(x)), \quad f(\cdot) \geq 0, \quad g(\cdot) > 0. \quad (1)$$

Параметры θ называются *естественными параметрами*.

Несмотря на довольно необычный вид выражения, оказывается, что подавляющее большинство табличных распределений лежит в экспоненциальном классе (нормальное, все дискретные распределения, бета-распределение, гамма-распределение, хи-квадрат распределение и т.д.). То есть большинство распределений, с которыми приходится иметь дело в прикладных задачах, принадлежат экспоненциальному классу распределений.² Такие распределения обладают несколькими довольно примечательными свойствами, и мы рассмотрим некоторые из них. Начнем с достаточных статистик.

Для начала вспомним, что же такое достаточная статистика распределения. Неформальное определение можно сформулировать так: *достаточная статистика* — это функция от выборки, которая содержит всю информацию, необходимую для оценки параметров неизвестного распределения.

Определение несколько размытое. Формализуем его, воспользовавшись *критерием факторизации Фишера*:

Определение 2. $a(X)$ — достаточна тогда и только тогда, когда $p(X|\theta) = f_1(X)f_2(\theta, a(X))$

В общем случае таких статистик может не быть. Однако для экспоненциального класса распределений они существуют. Из функционального вида распределения и критерия Фишера легко следует, что $u(x)$ является достаточной статистикой (можно взять $f_1(X) = f(X)$, $f_2(\theta, u(X)) = \frac{\exp(\theta^T u(X))}{g(\theta)}$).

Рассмотрим одно замечательное свойство экспоненциального класса распределений. Заметим, что

$$g(\theta) = \int f(x) \exp(\theta^T u(x)) dx, \quad \text{т.к.} \quad \int \frac{f(x)}{g(\theta)} \exp(\theta^T u(x)) dx = 1. \quad (2)$$

Продифференцируем по θ_j

$$\frac{\partial}{\partial \theta_j} g(\theta) = \frac{\partial}{\partial \theta_j} \int f(x) \exp(\theta^T u(x)) dx = \int f(x) \exp(\theta^T u(x)) u_j(x) dx = \quad (3)$$

$$= g(\theta) \int \frac{f(x)}{g(\theta)} \exp(\theta^T u(x)) u_j(x) dx = g(\theta) \int p(x|\theta) u_j(x) dx = g(\theta) \mathbb{E}_{x \sim p(x|\theta)} u_j(x). \quad (4)$$

¹Как мы увидим далее, многие методы обучения моделей со скрытыми переменными являются вариациями ЕМ-алгоритма.

²Стоит заметить, что такое популярное в приложениях распределение, как смесь нормальных распределений, не принадлежит экспоненциальному классу

В итоге получаем, что

$$\frac{\partial}{\partial \theta_j} \log g(\theta) = \mathbb{E}_{x \sim p(x|\theta)} u_j(x). \quad (5)$$

Таким образом, мы получили простой способ находить математическое ожидание от достаточной статистики для распределения из экспоненциального класса — нужно просто продифференцировать логарифм его нормировочной константы. Аналогично можно показать, что

$$\frac{\partial^2}{\partial \theta_j \partial \theta_k} \log g(\theta) = \text{cov}(u_j(x), u_k(x)). \quad (6)$$

Из выражения 6 следует, что $\nabla^2 \log g(\theta) \succ 0$ (положительно определенная матрица), то есть $\log g(\theta)$ — выпуклая функция.

Теперь посмотрим сможем ли мы определить выпуклость или вогнутость логарифма правдоподобия распределения из экспоненциального класса. Мы знаем, что:

$$\log p(x|\theta) = \log f(x) - \log g(\theta) + \theta^T u(x), \quad (7)$$

$f(x)$ не зависит от θ , $\log g(\theta)$ является выпуклой функцией, а $\theta^T u(x)$ является одновременно выпуклой и вогнутой. Из этого мы получаем, что $\log p(x|\theta)$ вогнутая функция, так как $-\log g(\theta)$ является вогнутой, а сумма вогнутых (выпуклых) функций также является вогнутой (выпуклой) функцией. Мы могли бы не пользоваться этими рассуждениями, а получить, что $\nabla_{\theta}^2 \log p(x|\theta) = -\nabla_{\theta}^2 \log g(\theta) \prec 0$.

3.2 Проблемы в оптимизации правдоподобия

Итак, мы будем решать следующую задачу:

Задача 1. По выборке X восстановить параметры θ распределения методом максимального правдоподобия:

$$p(X|\theta) \rightarrow \max_{\theta}.$$

Вопрос. В каких параметрических семействах эту задачу можно решить эффективно?


Ответ. Если плотность распределения $p(X|\theta)$ лежит в экспоненциальном классе, то мы можем эффективно найти оценку максимального правдоподобия для параметров θ . Иногда это возможно в явном виде (дифференцируем логарифм правдоподобия, приравняем к нулю, и находим из полученной системы уравнений параметры θ), а в остальных случаях можно построить эффективную численную процедуру оценки (благодаря тому, что логарифм функции правдоподобия — вогнутая функция³).

Проблема заключается в том, что экспоненциальный класс не такой широкий, как могло бы показаться. Зачастую на практике наблюдаемые данные имеют гораздо более сложное распределение, которое в экспоненциальный класс никак не вписывается. Возникает дилемма:


- либо пытаться «натянуть ежа на глобус» и вписать распределение из экспоненциального класса в выборку, которая пришла из более сложного распределения (оно будет плохо описывать данные, но зато мы сможем эффективно решить Задачу 1);
- либо переходить к гораздо более сложным семействам распределений, обладающим достаточной гибкостью, чтобы описать данные, но в этом случае процесс нахождения максимума в Задаче 1 может сходиться слишком медленно.

³Даже в пространствах высокой размерности для вогнутых функций существуют эффективные способы нахождения глобального максимума.

Пример. Рассмотрим следующую одномерную выборку:




Можно попытаться восстановить плотность распределения выбрав какое-то параметрическое семейство из экспоненциального класса. Например, нормальные распределения. Получим примерно следующую гауссиану:




Она наиболее правдоподобно описывает наблюдаемые данные в семействе нормальных распределений. Однако с точки зрения здравого смысла, модель не очень хорошая. Данные явно пришли не из гауссианы.

С другой стороны можем предположить, что данные приходят из нескольких гауссиан:



Тогда можем восстановить параметры каждой из гауссиан:



К сожалению, у нас нет информации о цветах, т.е. мы не знаем, какой объект из какой гауссианы пришёл. Однако, если бы у нас была такая информация, то задача восстановления плотности распределения сразу стала бы гораздо проще, потому что свелась бы к решению Задачи 1 для нескольких плотностей из экспоненциального класса.

На этом и строится идеология моделей с латентными переменными: мы говорим, что наши данные пришли из довольно сложного распределения, и имеют сложную природу; но если бы мы знали что-нибудь ещё, какие-то дополнительные переменные, то наше распределение стало бы гораздо более простым.

Можно показать, что для любого распределения не из экспоненциального класса можно ввести дополнительные (латентные) переменные так что совместное распределение на исходные и латентные переменные будет лежать в экспоненциальном классе. Итак, вместо того чтобы решать задачу 1 мы будем решать следующую задачу:

Задача 2. Введём латентные переменные Z так, чтобы совместное распределение $p(X, Z | \theta)$ лежало в экспоненциальном классе. Вместо решения исходной задачи (которую мы теперь будем называть задачей максимизации неполного правдоподобия) будем решать задачу

$$p(X, Z | \theta) \rightarrow \max_{\theta}.$$

Замечание. Помимо того что мы решим исходную задачу, мы также получим информацию о возможных значениях латентных переменных. На практике существует много задач, в которых информация о Z гораздо важнее информации о θ . В дальнейшем мы рассмотрим несколько таких примеров.

3.3 Вывод ЕМ-алгоритма

Итак, пусть мы смогли ввести такие дополнительные переменные Z , что совместное распределение $p(X, Z | \theta)$ стало лежать в экспоненциальном классе. Таким образом, мы можем сравнительно легко найти оценку максимального правдоподобия на параметры θ . В частности, функция $\log p(X, Z | \theta)$ вогнута по θ при фиксированных X и Z .

Записываем цепочку тождеств:⁴

$$\begin{aligned} \log p(X | \theta) &= \int q(Z) \log p(X | \theta) dZ = \\ &= \int q(Z) \log \frac{p(X, Z | \theta)}{p(Z | X, \theta)} dZ = \\ &= \int q(Z) \log \left[\frac{p(X, Z | \theta)}{p(Z | X, \theta)} \frac{q(Z)}{q(Z)} \right] dZ = \\ &= \int q(Z) \log \frac{p(X, Z | \theta)}{q(Z)} dZ + \int q(Z) \log \frac{q(Z)}{p(Z | X, \theta)} dZ. \end{aligned} \quad (8)$$

Здесь $q(Z)$ — произвольное распределение в пространстве латентных переменных. Рассмотрим повнимательнее получившиеся слагаемые. Для этого вспомним определение и некоторые свойства дивергенции Кульбака-Лейблера.

Определение 3. Дивергенция Кульбака-Лейблера между двумя распределениями p и q определяется следующим образом:

$$KL(p(x) \parallel q(x)) = \int p(x) \log \frac{p(x)}{q(x)} dx.$$

Свойство (KL -дивергенции). $KL(p \parallel q) \geq 0$, причём $KL(p \parallel q) = 0$ если и только если эти распределения почти всюду (везде кроме множества меры ноль) совпадают.

Упражнение. Докажите это свойство при помощи неравенства Йенсена.

Замечание. У KL -дивергенции есть теоретико-информационный смысл. Если мы работаем с дискретными случайными величинами, KL -дивергенция показывает, на сколько дополнительных бит длиннее будет сообщение при не оптимальном кодировании: если символы приходят из распределения p , а кодируем мы их как будто они приходят из распределения q .

Вернемся к (8). Заметим, что первое слагаемое не является KL -дивергенцией, поскольку у него под логарифмом стоит отношение совместного распределения $p(X, Z | \theta)$ и $q(Z)$, а эти распределения лежат в разных пространствах. А вот второе слагаемое является KL -дивергенцией распределений $q(Z)$ и $p(Z | X, \theta)$. Тогда, вследствие неотрицательности KL -дивергенции можем записать следующее неравенство:

$$\log p(X | \theta) \geq \int q(Z) \log \frac{p(X, Z | \theta)}{q(Z)} dZ \quad (9)$$

Идея ЕМ-алгоритма заключается в том, чтобы вместо оптимизации логарифма неполного правдоподобия оптимизировать полученную нижнюю оценку, но теперь уже как по θ так и по распределению q .

⁴Поскольку $\log p(X | \theta)$ от Z не зависит, то первый переход является домножением на единицу: $\int q(Z) dZ = 1$. Во втором переходе используется правило для условной вероятности. Третий переход — опять умножение на единицу. Наконец в последнем переходе мы сгруппировали числители и знаменатели под логарифмом «накрест» и разбили логарифм произведения на сумму двух логарифмов.

Определение 4. Правая часть выражения 9 называется нижней границей на обоснованность (ELBO, evidence lower bound) и обозначается $\mathcal{L}(q, \theta)$.

Вспомним красивый прием из вычислительной математики, которые помогут нам про-максимизировать неполное правдоподобие.

Определение 5. Пусть $f(x)$ — некоторая функция действительного переменного. Тогда семейство функций двух переменных $g(x, \xi)$, обладающее свойствами

1. $\forall x, \forall \xi \quad f(x) \geq g(x, \xi),$
2. $\forall x \exists \xi(x) : f(x) = g(x, \xi(x)),$

называется вариационной нижней оценкой функции f .

Вариационная нижняя оценка является нижней оценкой, и при этом в любой точке x можем так подобрать параметр ξ так, что оценка становится точной. Простейшим примером вариационной нижней оценки служит касательная к выпуклой функции.

Если $g(x, \xi)$ — вариационная нижняя оценка для $f(x)$, то мы можем решить задачу максимизации функции $f(x)$ по x с помощью следующей итеративной процедуры:

$$\begin{cases} x_n = \arg \max_x g(x, \xi_{n-1}), \\ \xi_n = \arg \max_{\xi} g(x_n, \xi) \end{cases} \quad (10)$$

Можно показать, что такая итеративная процедура сходится в стационарную точку функции $f(x)$. Такая замена оптимизируемой функции может быть удобна, если максимум исходной функции $f(x)$ искать тяжело, а максимизировать вариационную нижнюю оценку $g(x, \xi)$ — просто.

Вопрос. Является ли нижняя граница на обоснованность вариационной нижней оценкой. Почему?

Ответ. Напомним, что вариационная нижняя оценка требует выполнения двух свойств:

- она всегда не превосходит выражения которое она оценивает (этому как раз удовлетворяет (9));
- для любого аргумента исходной функции (θ) найдутся такие значения вариационных (q), для которых неравенство превращается в равенство. В самом деле, если взять $q(Z) = p(Z | X, \theta)$, тогда их KL -дивергенция обратится в ноль, а неравенство — в равенство.

Благодаря этому свойству мы можем перейти от оптимизации неполного правдоподобия к оптимизации нижней оценки на обоснованность. Будем решать полученную задачу итерационно:

- оптимизировать по q при фиксированном θ (E -шаг):

$$\mathcal{L}(q, \theta_0) \rightarrow \max_q \implies q(Z) = p(Z | X, \theta); \quad (11)$$

- оптимизировать по θ при фиксированном q (M -шаг):

$$\mathcal{L}(q_0, \theta) \rightarrow \max_{\theta} \iff \int q(Z) \log p(X, Z | \theta) dZ \rightarrow \max_{\theta}. \quad (12)$$

На E -шаге у нас задача функциональной оптимизации. В общем случае такие задачи решать эффективно невозможно. Однако есть одно обстоятельство, которое позволяет легко с этим разобраться. А именно, сумма в (8) не зависит от q , а потому максимизация по q первого слагаемого эквивалентна минимизации по q второго слагаемого, а второе слагаемое — KL -дивергенция. Мы знаем, где она достигает минимума, потому и приравняем $q(Z) = p(Z | X, \theta)$. Таким образом, если модель позволяет выполнить аналитический байесовский вывод на латентные переменные (т.е. найти апостериорное распределение $p(Z | X, \theta)$), то E -шаг продельвается в явном виде.

3.4 Обсуждение ЕМ-алгоритма и примеры

Вопрос. Что делать, если невозможно аналитически посчитать апостериорное распределение $p(Z | X, \theta)$ на Е-шаге?

Ответ. В этом случае Е-шаг выполняется приближенно⁵. Как было замечено выше, максимизация нижней оценки на обоснованность по q эквивалентна минимизации KL -дивергенции между $q(Z)$ и апостериорным распределением $p(Z | X, \theta)$. Поэтому приближенный Е-шаг будет выглядеть так:

$$q(Z) = \arg \min_{q \in Q} KL(q(Z) \parallel p(Z | X, \theta)),$$

где Q — некоторое параметрическое семейство, в котором мы ищем оптимальное $q(Z)$.

Вопрос. Что будет, если $Q = \Delta$, где Δ — семейство всевозможных δ -функций?

Ответ. Получим «байесовский вывод для бедных», т.е. точечную оценку на параметры θ , максимизирующую апостериорное распределение $p(Z | X, \theta)$:

$$\int \delta(Z - Z_0) \log \frac{\delta(Z - Z_0)}{p(Z | X, \theta)} dZ \rightarrow \min_{Z_0},$$

что эквивалентно

$$C - \int \delta(Z - Z_0) \log p(Z | X, \theta) dZ \rightarrow \min_{Z_0},$$

или же

$$\log p(Z_0 | X, \theta) \rightarrow \max_{Z_0}.$$

Т.е. «байесовский вывод для бедных» является приближением апостериорного распределения с помощью дельта-функции.

Таким образом, Е-шаг всегда можно проделать приближённо, даже если сопряженных распределений нет и аналитический вывод невозможен.

Вопрос. Что можно сказать про М-шаг? На первый взгляд, максимизируется какое-то матожидание, какой-то интеграл, который может даже не взяться. Что делать?

Ответ. Напомним, что $\log p(X, Z | \theta)$ вогнутая по θ функция (мы так вводили скрытые переменные Z). Однако мы оптимизируем не её саму, а её матожидание. К счастью, матожидание вогнутой функции — функция также вогнутая.⁶ Таким образом, даже если аналитическая оптимизация такого выражения невозможна, то численная всегда возможна и эффективна, даже в пространствах высокой размерности.

Итак, резюмируя, Е-шаг иногда можно выполнить аналитически или хотя бы сделать «байеса для бедных», а на М-шаге у нас задача оптимизации вогнутой функции. Так выглядит классический ЕМ-алгоритм (формулы 11 12). Существуют разные экспериментальные постановки при которых эти процессы необходимо модифицировать. Например, есть стохастический ЕМ-алгоритм, МЕ-алгоритм, вариационный ЕМ-алгоритм и множество других модификаций. Все они так или иначе опираются на эту базовую схему, немного её модифицируя.

Пример. Предположим мы попали в следующую ситуацию: на Е-шаге возможно аналитически рассчитать распределение $p(Z | X, \theta_0)$, а на М-шаге неберущийся интеграл и для нахождения максимума приходится выполнять большое количество итераций численного метода оптимизации.

⁵ЕМ-алгоритм с таким Е-шагом называется приближенным. Тем не менее, он будет обладать рядом приятных свойств. В частности, вариационная нижняя оценка будет монотонно расти, а потому алгоритм будет гарантированно сходиться. Но, вообще говоря, необязательно к точке локального максимума неполного правдоподобия

⁶Поскольку выпуклая комбинация вогнутых функций — вогнутая функция, а любое матожидание — это выпуклая комбинация из бесконечного числа слагаемых.

Вопрос. Как можно тогда оптимизировать (сделать более эффективной) процедуру?

Ответ. Например, на M -шаге необязательно дожидаться сходимости, можно выполнить одну либо небольшое количество итераций численного метода оптимизации.

Замечание. Бывает и наоборот, когда M -шаг быстрый, а на E -шаге приходится численно оптимизировать KL -дивергенцию. Тогда опять же можно останавливать численный метод оптимизации раньше.

В любом из таких случаев у нас всё равно будет выполняться свойство монотонного роста вариационной нижней оценки, а потому сходимость нам гарантирована.

Пример. Наиболее известным примером ЕМ-алгоритма, безусловно, выступает разделение смеси гауссиан.

Вопрос. Что выступает в роли латентных переменных для задачи разделения смеси гауссиан?

Ответ. Номера гауссиан из которых пришли объекты.

Если вспомнить, то алгоритм разделения смеси гауссиан представляет собой как раз таки (11) и (12): на E -шаге мы для каждого объекта рассчитываем вероятность того что он пришёл из каждой из гауссиан, а на M -шаге, хотя нигде явно и не записываем интеграл, но пользуемся взвешенными оценками максимального правдоподобия, которые как раз и являются аргмаксимумами (12).

3.5 Восстановление разметки с помощью ЕМ-алгоритма (GLAD)

Замечание. Часть материала взята с конспекта <https://github.com/esokolov/ml-course-hse/blob/master/2020-spring/seminars/sem15-em.pdf>, для желающих есть оригинальная статья.

Самой сложной частью при решении задач машинного обучения является сбор и обработка обучающих данных, к счастью, существуют сервисы, где исполнители за небольшую плату могут размечать данные заказчика (например, отвечать, улыбается ли человек на приведенном изображении). Примерами таких сервисов являются Amazon Mechanical Turk и Яндекс.Толока.

Эксперты, размечающие данные, не заинтересованы в качественной разметке или не обладают достаточной компетенцией, поэтому результирующие данные получаются зашумленными, что может сильно сказаться на качестве итогового алгоритма. Основным способом борьбы с данным эффектом является усреднение ответов по нескольким экспертам, то есть простое голосование. У данного способа есть очевидные проблемы: он не учитывает (1) компетенцию каждого эксперта и (2) сложность решаемой задачи.

Если мы предполагаем, что компетенция и сложность задачи так важны, то почему бы не использовать наши предположения (априорные знания) для создания алгоритма. Осталось формализовать рассуждения и придумать вероятностную модель, давайте сделаем это.

Рассмотрим датасет из ℓ изображений задачи бинарной классификации, для которого собраны ответы экспертов $l_{ij} \in \{0, 1\}$, где l_{ij} — разметка i -го изображения j -ым экспертом (наблюдаемые переменные), а также известны истинные метки изображений $z_i \in \{0, 1\}$, то есть скрытые переменные, которые мы хотим восстановить. Дополнительно зададим параметры $\alpha_j \in (-\infty, +\infty)$ — уровень экспертизы j -ого эксперта и $\beta_i \in (0, +\infty)$ такое, что $1/\beta_i$ представляет сложность i -ой задачи. Совместное распределение зададим следующим образом (l_i обозначает набор меток для i -ого изображения от всех экспертов):

$$p(l_{ij} = z_i | z_i, \alpha_j, \beta_i) = \sigma(\alpha_j \beta_i) = \frac{1}{1 + \exp(-\alpha_j \beta_i)},$$
$$p(z_i, l_i | \alpha, \beta_i) = p(z_i) \prod_j p(l_{ij} | z_i, \alpha_j, \beta_i).$$

По смыслу $p(l_{ij} = z_i | z_i, \alpha_j, \beta_i)$ означает, что i эксперт на j задаче оказался прав.

Почему мы задаем параметры и совместное распределение именно так? Оказывается, что такая вероятностная модель обладает несколькими свойствами, логичными для нашей задачи. Если мы зафиксируем β_i и рассмотрим $\alpha_j \rightarrow +\infty$, то получим $p(l_{ij} = z_i | z_i, \alpha_j, \beta_i) \rightarrow 1$, то есть такой эксперт всегда решает правильно любую задачу конечной сложности. Аналогично, при $\alpha_j \rightarrow -\infty$ мы получаем $p(l_{ij} = z_i | z_i, \alpha_j, \beta_i) \rightarrow 0$, то есть получается очень вредный эксперт, который намеренно (или от путаницы) портит нам разметку.

Теперь посмотрим на величину $1/\beta_i$. Если $1/\beta_i \rightarrow 0$, то для "хорошего" эксперта ($\alpha_j > 0$) получаем $p(l_{ij} = z_i | z_i, \alpha_j, \beta_i) \rightarrow 1$, а для "плохого" ($\alpha_j < 0$) выходит $p(l_{ij} = z_i | z_i, \alpha_j, \beta_i) \rightarrow 0$. То есть любой эксперт легко идентифицирует правильный класс картинки и выдает разметку исходя из своей вредности. Напротив, при $1/\beta_i \rightarrow +\infty$ получаем вероятность $p(l_{ij} = z_i | z_i, \alpha_j, \beta_i) \rightarrow 1/2$ как для "хороших", так и для "плохих" экспертов. Авторы этой вероятностной модели назвали её GLAD (Generative model of Labels, Abilities and Difficulties).

Оптимальные параметры α и β , а также распределение истинной разметки z_i мы будем искать с помощью ЕМ-алгоритма. Но для начала обратим внимание на априорное распределение $p(z_i)$. Его можно оставить равномерным $p(z_i = 0) = p(z_i = 1) = 1/2$, а можно внести в него наши представления о балансе классов среди картинок. Еще один вариант - ввести параметр $\pi = p(z_i = 1)$ и вести оптимизацию по нему на М-шаге. Но мы оставим эту вероятность фиксированной.

Начнем вывод ЕМ-алгоритма с того, что приведем вероятностную модель к более удобному виду. Мы бы хотели работать с величиной $p(l_{ij} | z_i, \alpha_j, \beta_i)$, но нам задана только $p(l_{ij} = z_i | z_i, \alpha_j, \beta_i)$. Для начала запишем следующее выражение:

$$p(l_{ij} \neq z_i | z_i, \alpha_j, \beta_i) = 1 - p(l_{ij} = z_i | z_i, \alpha_j, \beta_i) = 1 - \sigma(\alpha_j \beta_i) = \sigma(-\alpha_j \beta_i)$$

Теперь мы можем перейти к записи с индикаторами:

$$\begin{aligned} p(l_{ij} | z_i, \alpha_j, \beta_i) &= p(l_{ij} = z_i | z_i, \alpha_j, \beta_i)^{[l_{ij}=z_i]} p(l_{ij} \neq z_i | z_i, \alpha_j, \beta_i)^{[l_{ij} \neq z_i]} = \\ &= \sigma(\alpha_j \beta_i)^{[l_{ij}=z_i]} \sigma(-\alpha_j \beta_i)^{[l_{ij} \neq z_i]} \end{aligned}$$

Соответственно, совместное распределение на наблюдаемые и латентные переменные выглядит так:

$$p(z_i, l_i | \alpha, \beta_i) = p(z_i) \prod_j \left(\sigma(\alpha_j \beta_i)^{[l_{ij}=z_i]} \sigma(-\alpha_j \beta_i)^{[l_{ij} \neq z_i]} \right)$$

- Е-шаг

$$\begin{aligned} q(z_i) &:= p(z_i | l, \alpha, \beta) = p(z_i | l_i, \alpha, \beta_i) = \frac{p(z_i, l_i | \alpha, \beta_i)}{p(l_i | \alpha, \beta_i)} = \frac{p(z_i, l_i | \alpha, \beta_i)}{\sum_{z \in \{0,1\}} p(z, l_i | \alpha, \beta_i)} = \\ &= \frac{p(z_i) \prod_j \left(\sigma(\alpha_j \beta_i)^{[l_{ij}=z_i]} \sigma(-\alpha_j \beta_i)^{[l_{ij} \neq z_i]} \right)}{\sum_{t \in \{0,1\}} p(t) \prod_j \left(\sigma(\alpha_j \beta_i)^{[l_{ij}=t]} \sigma(-\alpha_j \beta_i)^{[l_{ij} \neq t]} \right)} \end{aligned}$$

Замечание. Из соображений численной устойчивости на практике обычно считают логарифмы вероятности $\log p(t, l_i | \alpha, \beta_i)$, а затем применяют оператор *Softmax*:

$$\begin{aligned} \gamma_i^t &= \log p(t, l_i | \alpha, \beta_i) = \log p(t) + \sum_j \left([l_{ij} = t] \log \sigma(\alpha_j \beta_i) + [l_{ij} \neq t] \log \sigma(-\alpha_j \beta_i) \right) \\ q_i(z_i) &= \frac{\exp(\gamma_i^{z_i})}{\sum_{t \in \{0,1\}} \exp(\gamma_i^t)} \end{aligned}$$

- М-шаг

Вспомним, что на М-шаге нам нужно решить следующую оптимизационную задачу:

$$\mathbb{E}_{z \sim q(z)} \log p(z, l | \alpha, \beta) \rightarrow \max_{\alpha, \beta}$$

Очень часто бывает так, что этот оптимум можно найти аналитически, для этого нужно приравнять градиент математического ожидания к нулю и решить получившееся уравнение относительно α и β . Однако здесь нам не повезло, уравнение на градиент не решается аналитически, поэтому мы прибегнем к градиентным методам оптимизации. Для этого найдем градиент математического ожидания по α и β .

Для начала немного распишем само математическое ожидание (все слагаемые, не зависящие от α и β мы уберем в константу — все равно они никак не повлияют на градиент):

$$\begin{aligned}
\mathbb{E}_{z \sim q(z)} \log p(z, l | \alpha, \beta) &= \\
&= \mathbb{E}_{z \sim q(z)} \left[\log \prod_i p(z_i, l_i | \alpha, \beta_i) \right] = \mathbb{E}_{z \sim q(z)} \left[\sum_i \log p(z_i, l_i | \alpha, \beta_i) \right] = \\
&= \sum_i \mathbb{E}_{z_i \sim q_i(z)} \left[\log p(z_i, l_i | \alpha, \beta_i) \right] = \sum_i \mathbb{E}_{z_i \sim q_i(z)} \left[\log \left(p(z_i) \prod_j p(l_{ij} | z_i, \alpha_j, \beta_i) \right) \right] = \\
&= \sum_i \left(\mathbb{E}_{z_i \sim q_i(z)} \left[\log p(z_i) \right] + \sum_j \mathbb{E}_{z_i \sim q_i(z)} \left[\log p(l_{ij} | z_i, \alpha_j, \beta_i) \right] \right) = \\
&= \sum_i \sum_j \mathbb{E}_{z_i \sim q_i(z)} \left[\log p(l_{ij} | z_i, \alpha_j, \beta_i) \right] + \text{const} = \\
&= \sum_i \sum_j \sum_{t \in \{0,1\}} q_i(t) \log p(l_{ij} | t, \alpha_j, \beta_i) + \text{const} = \\
&= \sum_i \sum_j \sum_{t \in \{0,1\}} q_i(t) \left([l_{ij} = t] \log \sigma(\alpha_j \beta_i) + [l_{ij} \neq t] \log \sigma(-\alpha_j \beta_i) \right) + \text{const}
\end{aligned}$$

Вычислим несколько вспомогательных производных:

$$\begin{aligned}
\frac{d}{dx} \log \sigma(x) &= -\frac{d}{dx} \log(1 + \exp(-x)) = \frac{\exp(-x)}{1 + \exp(-x)} = \frac{1}{\exp(x) + 1} = \sigma(-x) \\
\frac{\partial}{\partial \alpha_j} \log \sigma(\alpha_j \beta_i) &= \beta_i \sigma(-\alpha_j \beta_i) & \frac{\partial}{\partial \alpha_j} \log \sigma(-\alpha_j \beta_i) &= -\beta_i \sigma(\alpha_j \beta_i) \\
\frac{\partial}{\partial \beta_i} \log \sigma(\alpha_j \beta_i) &= \alpha_j \sigma(-\alpha_j \beta_i) & \frac{\partial}{\partial \beta_i} \log \sigma(-\alpha_j \beta_i) &= -\alpha_j \sigma(\alpha_j \beta_i)
\end{aligned}$$

Осталось собрать все вместе:

$$\begin{aligned}
\frac{\partial}{\partial \alpha_j} \mathbb{E}_q \log p(z, l | \alpha, \beta) &= \sum_i \sum_{t \in \{0,1\}} q_i(t) \beta_i \left([l_{ij} = t] \sigma(-\alpha_j \beta_i) - [l_{ij} \neq t] \sigma(\alpha_j \beta_i) \right) \\
\frac{\partial}{\partial \beta_i} \mathbb{E}_{q^*} \log p(z, l | \alpha, \beta) &= \sum_j \sum_{t \in \{0,1\}} q_i(t) \alpha_j \left([l_{ij} = t] \sigma(-\alpha_j \beta_i) - [l_{ij} \neq t] \sigma(\alpha_j \beta_i) \right)
\end{aligned}$$

Теперь, когда у нас есть доступ к градиенту по параметрам, мы можем оптимизировать матожидание с помощью градиентного подъема или даже какого-нибудь более продвинутого метода оптимизации. Однако на практике часто оказывается достаточно делать один или несколько шагов в сторону градиента, не дожидаясь полной сходимости, а затем снова переходить к Е-шагу.