Примечание

Конспект подготовлен для ознакомления с материалами курса «Байесовские методы в анализе данных» 2026. Конспект опирается на лекции курса «Байесовские методы в машинном обучении». Конспект может содержать опечатки и неточности. Актуальный GitHub.

Содержание

Лекция 4. Методы Монте-Карло с Марковскими цепями (MCMC) 2
4.1 Общие предпосылки метода Монте-Карло . . . 2
4.2 Общие методы генерации выборок из одномерных распределений . . . 3
4.2.1 Простейшие методы . . . 3
4.2.2 Метод Rejection Sampling . . . 4
4.2.3 Метод Importance sampling . . . 6
4.3 Метод Метрополиса-Хастингса . . . 7
4.4 Схема Гиббса . . . 10

Лекция 4. Методы Монте-Карло с Марковскими цепями (MCMC)

4.1 Общие предпосылки метода Монте-Карло

Часто в задачах машинного обучения возникает задача оценивания математического ожидания функции $f(x)$ по распределению $p(x)$: $\mathbb{E}_{p(x)}f(x) = \int f(x)p(x)dx$. Где x, чаще всего, является вектором высокой размерности. Примерами подсчёта такого интеграла являются нахождение следующих распределений:

1. Обоснованность: $p(T \mid X) = \int p(T \mid X, \omega)p(\omega)d\omega$, где (X, T) — обучающая выборка, ω — параметры распределения.

2. Прогнозное распределение: $p(t \mid x, X, T) = \int p(t \mid x, \omega)p(\omega \mid X, T)d\omega$, где x — объект, для которого мы хотим получить прогнозное распределение на предсказание t.

На практике этот интеграл чаще всего не получается посчитать аналитически, поэтому применяют численные методы. Однако сложность классических численных методов интегрирования возрастают экспоненциально при увеличении размерности пространства.

В предыдущих лекциях мы уже имели дело с неберущимися интегралами, которые мы приближали с помощью EM-алгоритма и/или Mean Field аппроксимации. Однако в этих случаях приближённая оценка получалась смещённой. Можно ли как-то решить задачу интегрирования в высокоразмерном пространстве с использованием несмещённой оценки? В этом нам поможет метод Монте-Карло:

Заметим, что мы имеем дело не с произвольным интегралом, а с математическим ожиданием функции $f(x)$ по распределению $p(x)$. Приблизим его, произведя сэмплирование из распределения $p(x)$:

$$I = \int f(x)p(x)dx \approx \frac{1}{K}\Sigma_{k=1}^{K} f(x_k) = J, \quad x_k \sim p(x). \tag{1}$$

Поскольку все x_i случайные величины, то и J – случайная величина. Посчитаем её математическое ожидание:

$$\mathbb{E}J = \mathbb{E}\frac{1}{K}\sum_i f(x_i) = \frac{1}{K}\sum_i \mathbb{E}f(x_i) = \frac{K}{K}\,\mathbb{E}\,f(x) = \mathbb{E}f(x) = I. \tag{2}$$

Следовательно, J является несмещённой оценкой интеграла $\mathbb{E}_{p(x)}f(x)$. Теперь найдём дисперсию J:

$$\mathbb{D}J = \mathbb{D}\frac{1}{K}\sum_i f(x_i) = \frac{1}{K^2}\sum_i \mathbb{D}f(x_i) = \frac{1}{K}\mathbb{D}f(x) = \tag{3}$$

$$= \frac{1}{K}\int p(x)(f(x) - \mathbb{E}f(x))^2 dx = \frac{1}{K}\int p(x)(f(x) - I)^2 dx. \tag{4}$$

И, как следствие из ЦПТ, $J \sim \mathcal{N}(J \mid I, \frac{1}{K}\mathbb{D}f(x))$. Следовательно, чем меньше дисперсия оценки, тем ближе J приближает исходное $\mathbb{E}_{p(x)}f(x)$. Этого можно достичь путём увеличения количества сэмплов.

Также стоит отметить, что дисперсия $\mathbb{D}f(x)$ зависит от поведения функции $f(x)$ и не зависит от размерности пространства. Т.е. если $f(x)$ меняется плавно в области носителя, то можно не брать много точек для приближения [1]. Если же $f(x)$ сильно флуктуирует, то для точной оценки понадобится много сэмплов.

Таким образом, задача подсчёта интеграла сводится к задаче генерации выборки из заданного распределения. Эта задача не такая тривиальная, как может показаться на первый взгляд, и для её решения нам как раз и пригодятся марковские цепи. Но сперва мы рассмотрим классические методы генерации сэмплов из распределений.

[1] Предельный случай — $f(x) \equiv const \Rightarrow \mathbb{D}f(x) = 0$, для приближения можно взять одну точку

4.2 Общие методы генерации выборок из одномерных распределений

4.2.1 Простейшие методы

В большинстве популярных языков программирования заложена возможность генерации случайной величины, равномерно распределённой на $[0,1]$, этому будем отталкиваться от того, что это мы делать умеем. Пусть $\xi \sim \mathcal{U}[0,1]$; $\mathbb{E}\xi = \frac{1}{2}$; $\mathbb{D}\xi = \frac{1}{12}$.

Если же мы хотим получить случайную величину из произвольного отрезка $\eta \sim \mathcal{U}[a,b]$, то можно сначала просэмплировать $\xi \sim \mathcal{U}[0,1]$, а потом линейно её преобразовать: $\eta = \xi(b-a)+a$.

Теперь рассмотрим сэмплирование из стандартного нормального распределения. Для этого можно сгенерировать n случайных величин из $\mathcal{U}[0,1]$ и воспользоваться ЦПТ:

$$S_n = \sum_{i=1}^{n} \eta_i, \quad \mathbb{D}S_n = \frac{n}{12}, \quad \mathbb{E}S_n = \frac{n}{2},$$
$$\eta = \frac{S_n - \frac{n}{2}}{\sqrt{\frac{n}{12}}}.$$

При достаточно больших значениях n, $\eta \sim \mathcal{N}(0,1)$. [2]. Получив стандартно-нормальную величину, легко получить нормально распределённую случайную величину, умножив на стандартное отклонение и добавив математическое ожидание. Если возникла необходимость генерации случайной величины из многомерного нормального семейства, то можно применить разложение Холецкого и свести задачу к одномерным генерациям.

Общим подходом для генерации случайной величины с заданной обратимой функцией распределения является следующий метод:

Пусть $F_X(x) = \mathbb{P}\{X < x\}$. Какой вид имеет функция распределения $F_X(X)$?

Распишем

$$\mathbb{P}\{F_X(X) < \xi\} = \mathbb{P}\{X < F_X^{-1}\xi\} = F_X(F_X^{-1}(\xi)) = \xi.$$

Из этого следует, что

$$X = F_X^{-1}(\xi);\ \xi \sim \mathcal{U}[0,1]$$

т.к. функция распределения равномерно распределённой случайной величины равна сумме значений аргументов на $[0,1]$.

Однако не для каждой функции можно выписать обратную функцию в явном виде. Приведём наиболее значимые распределения, для которых это возможно:

1. Показательное распределение:

$$p(x \mid \lambda) = \lambda e^{-\lambda x}, x \geq 0, \lambda > 0, \tag{5}$$
$$F(x) = 1 - e^{-\lambda x} = \xi \Rightarrow x = -\frac{1}{\lambda}\ln(1-\xi). \tag{6}$$

2. Распределение Коши — имеет тяжёлые хвосты, поэтому не существует моментов [3]. Возможно только определение моментов в смысле главного значения.

$$p(x) = \frac{1}{\pi}\frac{1}{1+x^2}, \tag{7}$$
$$F(x) = \frac{1}{\pi}\operatorname{arctg}(x) + \frac{1}{2} = \xi \Rightarrow x = \operatorname{tg}(\pi(\xi - \frac{1}{2})). \tag{8}$$

[2] В некоторых задачах используется генерация следующего вида: $\sum_{i=1}^{12} \xi_i - 6 \approx \mathcal{N}(0,1)$; $\xi_i \sim \mathcal{U}[0,1]$. Если посмотреть на дисперсию генерируемой по такой формуле величины, то она примет значение, равное 1, поскольку $\mathbb{D}\xi_i = \frac{1}{12}$. Качество приближения гарантировано, в какой-то мере, ЦПТ.

[3] Этот факт имеет интересную реализацию в жизни: Если у всех людей в аудитории время на часах распределено по Коши относительно настоящего времени, то сбор всей информации и усреднение не поможет определить точное время

4.2.2 Метод Rejection Sampling

Итак, не умеем генерировать явно из плотности $p(x)$. Идея — давайте промажорируем плотностью, из которой умеем генерировать

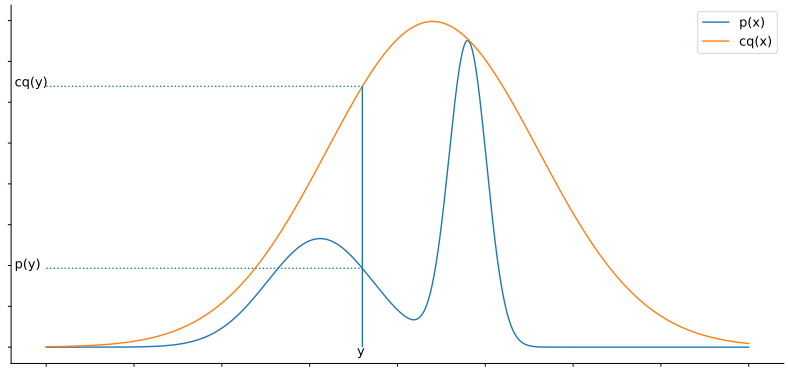


Рис. 1: Пример мажорирования плотностью в Rejection Sampling

Т.е. если $\forall x\ p(x) \leq cq(x)$, где c — мажорирующая константа (т.к. не каждую плотность можно промажорировать без нормировки), и мы умеем генерировать из плотности $q(x)$ (Рис. 1). Тогда будем принимать точку, сгенерированную из $q(x)$, только с определённой вероятностью, отражающей приближение.

Запишем формально: $y \sim q(y),\ \xi \sim \mathcal{U}[0, cq(y)] \Rightarrow$ accept y если $\xi < p(y)$

Докажем, что схема работает:

Фактически, мы утверждаем, что если x_{n+1} — следующая точка выборки, а $y \sim q(x)$, то мы примем y в качестве следующего сэмпла с вероятностью $\frac{p(y)}{cq(y)}$.

Запишем это как:

$$\mathbb{P}\{\text{accept}\} = \mathbb{E}_y \mathbb{P}\{\text{accept} \,|\, y\} = \int \frac{p(y)}{cq(y)} q(y) dy = \frac{1}{c} \tag{9}$$

Причём, чем ближе распределение $q(y)$ к распределению $p(x)$, тем меньше мажорирующая константа c, тем эффективнее работает схема — будет приниматься больше сэмплов.

Следовательно,

$$r(y \,|\, \text{accept}) = \frac{r(\text{accept} \,|\, y) r(y)}{r(\text{accept})} = \frac{\frac{p(y)}{cq(y)} q(y)}{\frac{1}{c}} = p(y). \tag{10}$$

Мы показали, что те сэмплы, которые мы приняли, будут иметь нужное распределение $p(y)$. ■

Как видно из формул, качество приближения определяется отношением площадей под плотностями, которое равно $\frac{1}{c}$ (см. формулу 9). Метод будет работать хорошо, если будет мало отклонений ($c \approx 1$), и если c будет большим, то необходимо будет больше точек для приближения.

Проблемные примеры:

Пример. *Пусть мы не умеем сэмплировать распределение Коши, хотим приблизить его нормальным распределением, из которого умеем (Рис. 2).*

В данном случае мы сколь угодно точно можем приблизить центральную часть распределения, однако, из-за того, что распределение Коши имеет тяжёлые хвосты, нам понадобится $c \to \infty$. В свою очередь, обратная схема приближения (нормальное — Коши) будет работать хорошо, т.к. гарантировано будет хорошее приближение на хвостах.

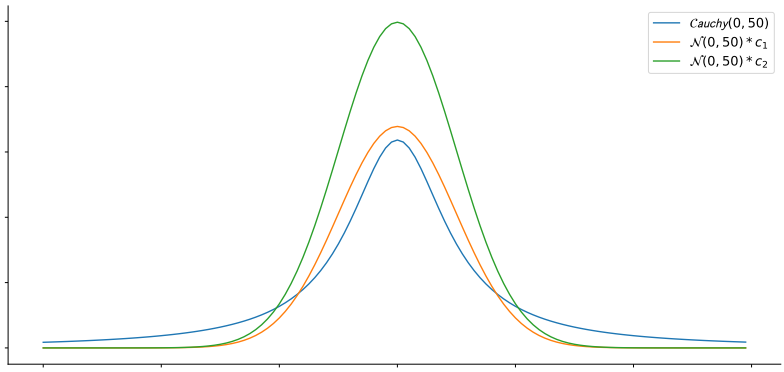


Рис. 2: Пример плохого приближения методом Rejection Sampling

Пример. *Если распределение стремится к виду δ-функции (Рис. 3), то в приближении мы будем генерировать много точек, хотя распределение задано, фактически, только в одной точке.*

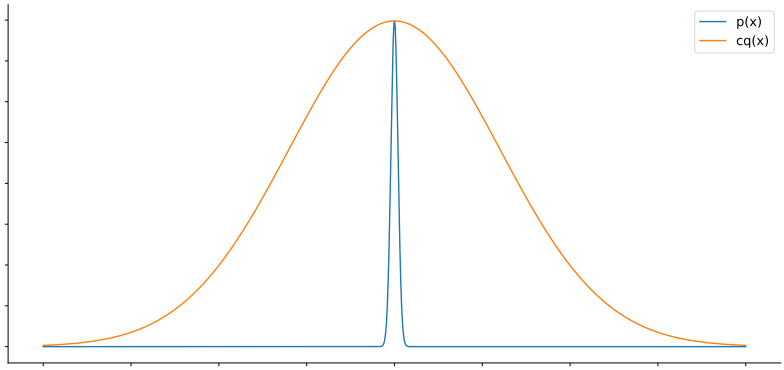


Рис. 3: Пример приближения в одной точке Rejection Sampling

В связи с этим хотелось бы внести информацию о важности сэмплированной точки. Это призван осуществить метод Importance sampling.

Как же улучшить метод Reject sampling на случай произвольного распределения, чтобы хорошее приближение было почти всегда? Т.к. эффективность схемы определяется отношением площадей под распределениями, то давайте попробуем построить решётку и приближать на каждом сегменте, исходное распределение, например, равномерным. А в хвостах, например, распределением Коши (можно взять так, чтобы площадь под хвостами была равна $\frac{1}{2}$). Тогда при использовании такого приближения и наличии умения считать площадь на каждом сегменте схема будет иметь следующий вид:

1) Реализуем дискретную случайную величину, равную количеству «бинов», чтобы понять, из какого сегмента будем сэмплировать дальше ($\mathbb{P}(\text{bin}) \propto S_{\text{bin}}$). Если выпал определённый «бин», реализуем на нём выборку из равномерного распределения.

2) Применяем Reject sampling на этом «бине».

Таким образом, улучшаем качество метода. В общем случае если носитель конечен, то приближаем равномерным распределением, а на хвостах — полубесконечным (например, показательным, т.к. умеем генерировать его и считать площадь под плотностью).

4.2.3 Метод Importance sampling

Метод призван уменьшить отклонения сэмплов. Это реализуется при помощи внедрения весов сэмпла:

$$\mathbb{E}_{p(x)} f(x) = \mathbb{E}_{q(x)} \frac{p(x)}{q(x)} f(x) \approx \frac{1}{K} \sum_{k=1}^{K} \frac{p(x_k)}{q(x_k)} f(x_k) = \sum_{k=1}^{K} v_k f(x_k), \tag{11}$$

где $v_k = \frac{1}{K} \frac{p(x_k)}{q(x_k)}$ и задаёт *важность* объекта $x_k \sim q(x)$. Снова получаем несмещённую оценку, но теперь берём все точки. Однако если v_i задаются сильно неравномерно (Рис. 4), то большие значения распределения будут вносить бóльший вклад.

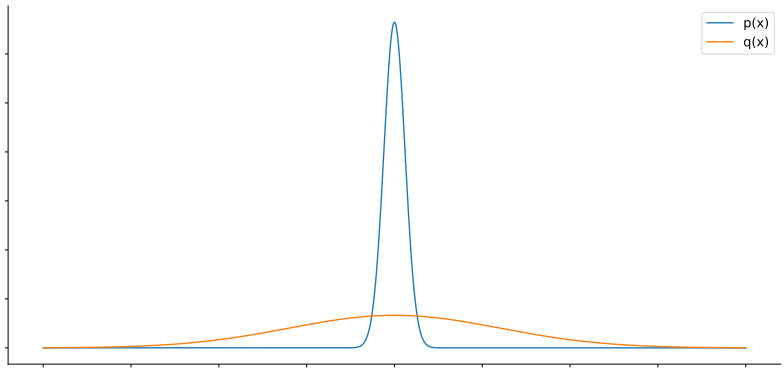


Рис. 4: Пример плохого выбора $q(x)$ в Importance sampling

Когда же важности будут распределены неравномерно? Когда распределения $p(x)$ и $q(x)$ сильно различаются. Но в таком виде Importance sampling запускать бессмысленно. Мы снова неявно предполагаем качественное приближение $p(x)$ распределением $q(x)$, и только в этом предположении схема становится эффективной (то есть v_i распределены равномерно), что важно для любого метода Монте-Карло, т.к. это медленно сходящиеся методы, в отличии от вариационной аппроксимации[4].

Плотность распределения $p(x)$ обычно представима в виде: $\frac{\hat{p}(x)}{B}$. И в случае, когда мы явно можем посчитать знаменатель B, проинтегрировав плотность, то получаем в нашей схеме явный байесовский вывод с апостериорной плотностью. Если же не можем посчитать нормировочную константу, то имеем дело только с $\hat{p}(x)$. Проверим, усложняет ли это схему:

$$\int p(x) f(x) dx = \frac{1}{B} \int \hat{p}(x) f(x) dx = \frac{\int \hat{p}(x) f(x) dx}{\int \hat{p}(x) dx} =$$

$$= \frac{\int q(x) \frac{\hat{p}(x)}{q(x)} f(x) dx}{\int q(x) \frac{\hat{p}(x)}{q(x)} dx} \approx \frac{\frac{1}{K} \sum\limits_{k=1}^{K} \frac{\hat{p}(x_k)}{q(x_k)} f(x_k)}{\frac{1}{K} \sum\limits_{k=1}^{K} \frac{\hat{p}(x_k)}{q(x_k)}} = \sum_{k=1}^{K} w_k f(x_k), \quad x_k \sim q(x). \tag{12}$$

[4]Имеем некоторую проблему tradeoff: Монте-Карло методы дают несмещённую оценку, однако долго приближают из-за высокой дисперсии, для сокращения которой необходимо большое по объёму сэмплирование, а вариационные методы дают смещённую оценку, меняя статистики от $f(x)$, но достаточно быстрые. Компромисс пытается найти современный подход — *неявное вероятностное моделирование*.

Если распределение $q(x)$ сильно не похоже на $p(x)$ (Рис. 4), то многие w_k будут близки к 0, но будет много сэмплов, точно не попавших в $p(x)$. В случае, когда мода распределения $q(x)$ находится далеко от моды $p(x)$, будет также происходить доминирование одной точки, попавшей в $p(x)$, над большим количеством точек с меньшими весами.

Итак, были рассмотрены основные методы сэмплирования и методы сэмплирования из одномерных плотностей. Но последние методы плохо переносятся на случай высокой размерности. Оказалось, что нам поможет аппарат Марковских цепей.

4.3 Метод Метрополиса-Хастингса

Основной идеей метода Метрополиса-Хастингса является отказ от сэмплирования из одного фиксированного распределения. Вместо этого предлагается сэмплировать последовательно из марковской цепи.

Определение 1. *Марковской цепью назовём бесконечную последовательность случайных величин $\{x_n\}_{n=1}^{\infty}$ такую, что $\forall n$ верно разложение:*

$$p(x_1, ..., x_n) = p_1(x_1)p_2(x_2 \mid x_1)p_3(x_3 \mid x_2) \dots p_n(x_n \mid x_{n-1}),$$

где функции $p_i(\cdot \mid \cdot)$ называют функциями перехода.

Важными видами марковских процессов являются те, у которых функция перехода не зависит от номера перехода.

Определение 2. *Марковская цепь называется гомогенной (или однородной), если*

$$\forall n: \quad p_n(x_n \mid x_{n-1}) = q(x_n \mid x_{n-1}).$$

В этом случае Марковская цепь определяется стартовым распределением $p_1(x_1)$ и вероятностью перехода $q(x' \mid x)$.

Пусть сгенерировали много переходов марковской цепи.

Какое распределение будет иметь x_1? Очевидно, это $p_1(x_1)$.

А чему равна функция $p_2(x_2)$? Для её нахождения достаточно провести процедуру маргинализации совместного распределения:

$$p_2(x_2) = \int p_2(x_2 \mid x_1)p_1(x_1)dx_1.$$

Эта закономерность повторяется и для дальнейших плотностей, например,

$$p_3(x_3) = \int p_3(x_3 \mid x_2)p_2(x_2)dx_2 = \int\int p_3(x_3 \mid x_2)p_2(x_2 \mid x_1)p_1(x_1)dx_1dx_2.$$

В дискретном случае — это выражение означало бы умножение матрицы на вектор, в непрерывном — скалярное произведение, т.е. действие линейного оператора в $\mathcal{L}_2$

Повторяется вид действия линейного оператора, который, в общем случае, для $f \in \mathcal{L}_2$ и K — лин. оператора, имеет вид: $g = Kf$, $g(y) = \int K(x, y)f(x)dx$.

Итак, мы поняли, что маргинальные плотности получаются действием линейного оператора. Обычно мы встречали такой вид в линейной алгебре. Может быть, можем получить какую-то сходимость последовательности плотностей?

Определение 3. *$p_*(x)$ называется инвариантным распределением (или стационарным) для гомогенной марковской цепи, если $p_*(x') = \int q(x' \mid x)p_*(x)dx$.*

Т.е. если мы были в распределении $p_*(x')$, то подействовав на него вероятностью перехода $q(x' \mid x)$, мы останемся в распределении $p_*(x')$.

Рассмотрим примеры функций перехода, ведь, фактически, от неё зависит наличие стационарных точек в марковской цепи.

Пример. *Пусть $q(x' \mid x) = \delta(x' - x)$. Тогда любое распределение $p_*(x)$ является стационарным. Если же $q(x' \mid x) = \delta(x' - x - a)$, то не существует инвариантных распределений.*

Следовательно, есть целый спектр функций перехода. Когда же гарантировано существование и единственность инвариантного распределения.

Определение 4. *Цепи, для которых существует единственное инвариантное распределение $p_*(x)$, будем называть эргодическими, если*

$$\forall p_1(x) \quad \lim_{n\to\infty} p_n(x) = p_*(x).$$

Поэтому в задаче генерации выборки мы можем построить одну эргодическую марковскую цепь и будем генерировать точки по ней. Тогда гарантировано, что мы сойдёмся к стационарному распределению. Но как сделать так, чтобы оно имело вид исходного распределения?

Определение 5. *Если $\forall x', x'' \in \mathcal{X}$, где $\mathcal{X}$ — носитель марковской цепи, справедливо, что $q(x'' \mid x') > 0$, следовательно, марковская цепь с $q(x'' \mid x')$ эргодическая.*

Что же это значит для нас? Пусть мы захотим генерировать выборку из $p(x)$. Если мы сможем построить однородную марковскую цепь с этим свойством такую, что её стационарное распределение будет совпадать с $p(x)$, то из любого начального приближения марковская цепь, начиная с какого-то момента, начнёт генерировать сэмплы из целевого распределения $p(x)$.

Теорема 1. *(Уравнение детального баланса Detailed Balance) Если для эргодичной однородной Марковской цепи и для $p_*(x)$ верно*

$$\forall x, x' \in \mathcal{X} \quad p_*(x)q(x' \mid x) = p_*(x')q(x \mid x'),$$

то p_* — инвариантное распределение.

Доказательство. Т.е. если в какой-то момент времени мы находимся в распределении $p_*(x)$ и в следующий момент времени мы также будем находиться в этом распределении, то докажем, что p_* — инвариантное (стационарное).

p_*:

$$\int q(x' \mid x)p_*(x)dx = \{\text{Уравнение DB}\} = \int p_*(x')q(x \mid x')dx = p_*(x') \underbrace{\int q(x \mid x')dx}_{=1} = p_*(x'). \quad \blacksquare$$

Почему это уравнение называется уравнением «баланса»? Пусть x, x' — страны, p_* — ВВП страны, а $q(x' \mid x)$ — то, какую долю ВВП страна x инвестирует в x'. Т.е. $q(x' \mid x)p_*(x)$ — сумма (напр. в \$), которую x тратит на x', а $q(x \mid x')p_*(x')$ — сумма, которую x' тратит на x. И если здесь получается равенство, то финансовые потоки сбалансированы, т.е. ВВП стран меняться не будет. Следовательно, если изначально был один ВВП страны, но потом страна фиксировала долю затрат на другие страны, как и другие, то всё сбалансируется. Причём если какие-то страны находятся в изоляции, то инвариантное распределение не единственно.

Теорема 2. *(Метод Метрополиса-Хастингса) Пусть имеется распределение $p(x) = \hat{p}(x)/B$, известное с точностью до нормировочной константы, и функция $r(x' \mid x) > 0\ \forall x', x \in \mathcal{X}$. Определим вероятность $A(x, x')$ принятия перехода из x в x' как*

$$A(x, x') = \min\left(1, \frac{\hat{p}(x')r(x \mid x')}{\hat{p}(x)r(x' \mid x)}\right) = \min\left(1, \frac{p(x')r(x \mid x')}{p(x)r(x' \mid x)}\right).$$

Тогда для $\forall x_0$ и марковской цепи с правилом перехода:

$$x_{n+1} = \begin{cases} x' \sim r(x' \mid x_n), & \text{с вероятностью } A(x_n, x'), \\ x_n, & \text{иначе}, \end{cases} \tag{13}$$

гарантируется, что $\exists N : \forall n \geqslant N \Rightarrow x_n \sim p(x_n) = \frac{\hat{p}(x)}{B}$.

Доказательство. Посмотрим, для начала, на формулу под min: Если рассмотреть симметричное[5] $r(x' \mid x) = r(x \mid x')$ [6]. Тогда берём x' с вероятностью $A(x, x') = \min(1, p(x')/p(x))$.

[5] Именно таковыми были предпосылки Метрополиса. Хастингс вывел для несимметричного случая

[6] Например, нормальное распределение с $\mathbb{E}y = x$ и дисперсией — любой изотропной ковариационной матрицей

То есть описанный процесс — это блуждание в пространстве иксов, при котором каждая следующая точка гарантированно принимается (если в ней плотность больше) либо принимается с некоторой вероятностью (пропорциональной отношению плотностей в текущей и предыдущей точках). Заметим, что если бы мы принимали только точки, увеличивающие плотность, то получился бы метод оптимизации, который ищет моду распределения $p(x)$.

Итак, описанная процедура сэмплирования задаёт марковскую цепь с функцией перехода

$$q(x' \mid x) = \underbrace{r(x' \mid x)}_{\text{Распределение новой точки } x'.} \times \underbrace{A(x, x')}_{\text{Вероятность принятия } x'} + \\ + \underbrace{\delta(x - x')}_{\text{Распределение точки}} \times \underbrace{(1 - \int A(x, y) r(y \mid x) dy)}_{\text{Вероятность репликации}}.$$

Во-первых, описанная марковская цепь эргодическая, поскольку свойство $q(x' \mid x) > 0, \forall x, x'$ наследуется от $r(x' \mid x) > 0$. Тогда если распределение $p(x)$ инвариантно для марковской цепи с функцией перехода $q(x' \mid x)$, то «прогретая» марковская цепь будет генерировать сэмплы из $p(x)$. Инвариантность $p(x)$ покажем с помощью уравнения детального баланса:

$$p(x) q(x' \mid x) \stackrel{?}{=} p(x') q(x \mid x'). \tag{14}$$

Рассмотрим левую часть уравнения 14:

$$p(x) q(x' \mid x) = p(x) r(x' \mid x) \min\left(1, \frac{p(x') r(x \mid x')}{p(x) r(x' \mid x)}\right) + \tag{15}$$

$$+ p(x) \delta(x - x') \left(1 - \int A(x, y) r(y \mid x) dy\right) = \tag{16}$$

второе слагаемое $\neq 0 \iff x' = x$, тогда заменим все x на x'; в первом слагаемом занесём $p(x) r(x' \mid x)$ в минимум:

$$\tag{17}$$

$$= \min\{p(x) r(x' \mid x), p(x') r(x \mid x')\} + \tag{18}$$

$$+ p(x') \delta(x - x') \left(1 - \int A(x', y) r(y \mid x') dy\right) \tag{19}$$

в первом слагаемом вынесем $p(x') r(x \mid x')$ из минимума:

$$= p(x') r(x \mid x') \underbrace{\min\left(\frac{p(x) r(x' \mid x)}{p(x') r(x \mid x')}, 1\right)}_{= A(x', x)} + \tag{20}$$

$$+ p(x') \delta(x - x') \left(1 - \int A(x', y) r(y \mid x') dy\right) \tag{21}$$

$$= p(x') q(x \mid x'). \tag{22}$$

Что и требовалось доказать. ■

Схема считается эффективной, если по ходу процесса точки-кандидаты x' принимаются с высокой частотой. Если же большая часть сгенерированных точек будет отвергаться, то в схеме будет много повторов, что можно считать недостатком метода. Ещё одним недостатком является корреляция между последовательными элементами. В принципе, это недостаток MCMC методов — высокая скоррелированность соседних случайных величин, а хотели бы выборку (Н.О.Р.С.В.).

Частичное решение этой проблемы — брать каждый n-ый элемент. Но в общем случае корреляция сохраняется, следовательно, возникает задача подбора q такой, чтобы была высокая вероятность перехода.

Рассмотрим частный случай схемы Метрополиса-Хастингса, который называется схема Гиббса.

4.4 Схема Гиббса

Имеем многомерное распределение $p(X)$. Идея состоит в сэмплировании каждой координаты по очереди, для этого используются условные вероятности. Схема такая:

$$
\begin{aligned}
x_1^{(k+1)} &\sim p(x_1 \,|\, x_2^{(k)}, x_3^{(k)}, \ldots, x_d^{(k)}), \\
x_2^{(k+1)} &\sim p(x_2 \,|\, x_1^{(k+1)}, x_3^{(k)}, \ldots, x_d^{(k)}), \\
&\ldots \\
x_d^{(k+1)} &\sim p(x_d \,|\, x_1^{(k+1)}, x_2^{(k+1)}, \ldots, x_{d-1}^{(k+1)}).
\end{aligned}
$$

Очевидным преимуществом схемы Гиббса является тот факт, что сэмплирование происходит из одномерного распределения, а для этого существуют сравнительно эффективные подходы, например, упоминаемый выше Rejection Sampling. Кроме того, в схеме Гиббса нет репликаций и вычисления $A(x, x')$ (часто подсчёт корректировки является вычислительно трудным) в отличие от схемы Метрополиса-Хастингса.

К недостаткам можно отнести невозможность распараллеливания вычислений из-за того, что каждый сэмпл получается от непосредственно предыдущего. Ещё одной проблемой является сложность сэмплирования из распределений с несколькими модами, поскольку одна марковская цепь с высокой вероятностью будет блуждать около одной модой и лишь изредка будет «перепрыгивать» с моды на моду.