Примечание

Конспект подготовлен для ознакомления с материалами курса «Байесовские методы в анализе данных» 2026. Конспект опирается на лекции курса «Байесовские методы в машинном обучении». Конспект может содержать опечатки и неточности. Актуальный GitHub.

Содержание

Лекция 5. Диффузионные модели **2**
5.1 Генеративные модели 2
5.2 Процесс зашумления (Forward process) 2
5.3 Процесс генерации (Backward process) 3
5.4 Обучение процесса генерации 4
5.5 Параметризация диффузионной модели 6
5.6 Метрика качества 7

Лекция 5. Диффузионные модели

В этой лекции мы разберём диффузионные модели из статьи Denoising diffusion probabilistic models (DDPM). Мы будем следовать оригинальной статье.

5.1 Генеративные модели

В глубоком обучении есть различные подходы к генерации изображений, наиболее известные — Generative Adversarial Networks (GAN), Variational Autoencoder (VAE). Оба подхода появились примерно в одно время.

Мы хотим получить генеративную модель, которая генерирует качественные и разнообразные сэмплы и делает это вычислительно эффективно. Если мы рассмотрим существующие подходы, то столкнёмся с тем, что GAN генерируют качественные сэмплы, но часто имеют проблемы с разнообразием; VAE генерирует разнообразные сэмплы, но часто размытые. К счастью, оба метода работают достаточно эффективно, так как для генерации требуют одного обращения к обученной нейронной сети, то есть стоимость генерации сравнима по времени с итерацией обучения.

Мы разберём диффузионные модели, которые генерируют качественные и разнообразные сэмплы, однако требуют больших временных затрат на генерацию. С другой стороны, эффективность можно повышать разными способами: новыми алгоритмами, ростом вычислительных мощностей и т. д. Например, современные диффузионные модели по времени генерации сопоставимы с GAN и VAE.

Часто требования по разнообразию, качеству и высокой эффективности называют **генеративной трилеммой**. В настоящее время диффузионные модели — это подход к генеративному моделированию, который в наибольшей степени удовлетворяет всем этим требованиям.

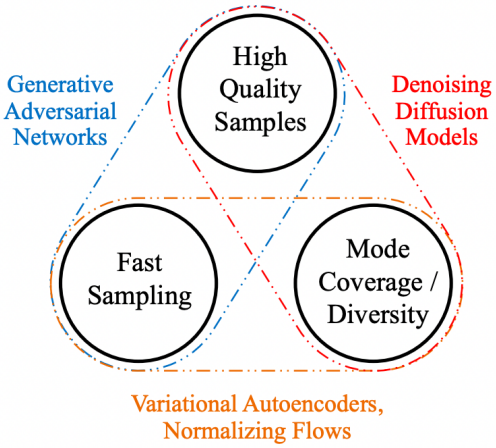


Рис. 1: Генеративная трилемма из статьи Tackling the Generative Learning Trilemma with Denoising Diffusion GANs.

5.2 Процесс зашумления (Forward process)

Если мы знаем, что за один шаг сгенерировать изображение сложно, то будем стараться делать много шагов генерации. Для этого нам было бы полезно превращать изображение x_0 в шум также за много шагов.

Мы будем зашумлять данные с помощью марковской цепи, в которой T шагов и ядро перехода:

$$q(x_t \mid x_{t-1}) = \mathcal{N}\left(x_t \mid \sqrt{1-\beta_t}x_{t-1}, \beta_t \mathbf{I}\right), \tag{1}$$

где $\beta_t \in (0,1)$ — гиперпараметр нашей модели. Тогда совместное распределение задаётся как

$$q(x_1, \dots, x_T \,|\, x_0) = \prod_{t=1}^{T} q(x_t \,|\, x_{t-1}). \tag{2}$$

Полученную марковскую цепь называют **процессом зашумления** или **Forward Process**. Отметим, что рассматриваемый процесс зашумления называется процессом, сохраняющим дисперсию (Variance preserving/VP). Это название следует из свойства, что если $\mathbb{D}\, x_0 = \mathbf{I}$, то $\mathbb{D}\, x_1 = (1-\beta_1)\mathbf{I} + \beta_1 \mathbf{I} = \mathbf{I}$, аналогично доказывается, что для любого t дисперсия сохраняется.

Далее мы выведем некоторые свойства этого процесса, которые в дальнейшем потребуются. Посмотрим, как выглядят переходы из x_0 в x_1 и из x_1 в x_2:

$$x_1 = \sqrt{1-\beta_1} x_0 + \sqrt{\beta_1}\varepsilon_1, \quad \varepsilon_1 \sim \mathcal{N}(0, \mathbf{I}), \tag{3}$$

$$x_2 = \sqrt{1-\beta_2} x_1 + \sqrt{\beta_2}\varepsilon_2, \quad \varepsilon_2 \sim \mathcal{N}(0, \mathbf{I}). \tag{4}$$

Теперь мы можем найти, какое распределение имеет x_2 при условии x_0:

$$x_2 = \sqrt{1-\beta_2} x_1 + \sqrt{\beta_2}\varepsilon_2 = \sqrt{1-\beta_2}\big[\sqrt{1-\beta_1} x_0 + \sqrt{\beta_1}\varepsilon_1\big] + \sqrt{\beta_2}\varepsilon_2 = \tag{5}$$

$$= \sqrt{1-\beta_2}\sqrt{1-\beta_1} x_0 + \sqrt{1-\beta_2}\sqrt{\beta_1}\varepsilon_1 + \sqrt{\beta_2}\varepsilon_2. \tag{6}$$

То есть x_2 при обусловливании на x_0 имеет нормальное распределение[1]. Найдём параметры распределения $q(x_2 \,|\, x_0)$:

$$\mathbb{E}[x_2 \,|\, x_0] = \sqrt{1-\beta_2}\sqrt{1-\beta_1} x_0 + \sqrt{1-\beta_2}\sqrt{\beta_1}\cdot 0 + \sqrt{\beta_2}\cdot 0, \tag{7}$$

$$\mathrm{Var}(x_2 \,|\, x_0) = (1-\beta_2)\beta_1 + \beta_2, \tag{8}$$

при вычислении условной дисперсии мы воспользовались тем, что ε_1 и ε_2 независимы. Заметим, что

$$1 - \mathrm{Var}(x_2 \,|\, x_0) = 1 - (1-\beta_2)\beta_1 - \beta_2 = (1-\beta_2)(1-\beta_1). \tag{9}$$

Следуя нотации из статьи DDPM, предлагается ввести следующие обозначения:

$$\alpha_t \coloneqq 1 - \beta_t, \quad \bar{\alpha}_t \coloneqq \prod_{s=1}^{t} \alpha_s. \tag{10}$$

Значит $q(x_2 \,|\, x_0) = \mathcal{N}\left(x_2 \mid \sqrt{\bar{\alpha}_2} x_0, (1-\bar{\alpha}_2)\mathbf{I}\right)$. Аналогично можно получить, что $q(x_t \,|\, x_0) = \mathcal{N}\left(x_t \mid \sqrt{\bar{\alpha}_t} x_0, (1-\bar{\alpha}_t)\mathbf{I}\right)$, то есть мы знаем переходную вероятность из x_0 на любой шаг t. Из этого следует, что при больших T (в статье $T = 1000$) $q(x_T \,|\, x_0) \approx \mathcal{N}\left(x_T \mid 0, \mathbf{I}\right)$, так как на практике $\bar{\alpha}_T \approx 0$.

Мы получили процесс зашумления, который превращает изображение в что-то очень похожее на шум.

5.3 Процесс генерации (Backward process)

Процесс генерации должен начинаться из $p(x_T) = \mathcal{N}\left(x_T \mid 0, \mathbf{I}\right)$. Зададим **процесс генерации** (Backward process) с помощью марковской цепи с переходными вероятностями $p_\theta(x_{t-1} \,|\, x_t)$, мы пока не уточняем, какое это семейство распределений и за что отвечают параметры θ. Если мы задали переходные вероятности, то мы можем посчитать совместное распределение

$$p_\theta(x_0, \dots, x_T) \coloneqq p(x_T) \prod_{t=1}^{T} p_\theta(x_{t-1} \,|\, x_t). \tag{11}$$

Процессы генерации и зашумления изображены на Рис. 2. Для генерации мы будем сэмплировать x_T из $p(x_T)$, а далее делать переходы $x_T \to x_{T-1}$ с помощью $p_\theta(x_{T-1} \,|\, x_T)$

[1] На самом деле, мы сделали свёртку двух нормальных распределений, похожий способ мы применили для получения предсказания байесовской линейной регрессии.

и так далее, пока не придём в x_0. Осталось определить, как именно задать $p_\theta(\cdot \mid \cdot)$, чтобы получались качественные изображения.

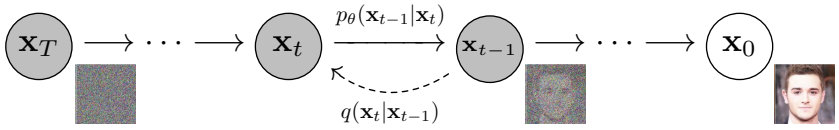


Рис. 2: Слева направо процесс генерации изображения (Backward); Справа налево процесс разрушения изображения (Forward)

5.4 Обучение процесса генерации

Мы хотим найти такой марковский процесс, чтобы x_0 было из распределения данных. Значит, наша задача формулируется как:

$$\log p_\theta(x_0) \coloneqq \log \int p_\theta(x_T, \dots, x_0) dx_T \dots dx_1 \to \max_\theta. \tag{12}$$

Однако мы не хотим максимизировать правдоподобие одного сэмпла, а всех сэмплов из распределения данных:

$$\mathbb{E}_{q(x_0)} \log p_\theta(x_0) = \mathbb{E}_{q(x_0)} \log \int p_\theta(x_T, \dots, x_0) dx_T \dots dx_1 \to \max_\theta, \tag{13}$$

где $q(x_0)$ — распределение данных. На практике обе эти задачи мы не можем решить, так как нужно оценить многомерный интеграл, где подынтегральная функция — нейронная сеть. Заметим, что x_0 — наблюдаемая величина, а $x_1, \dots, x_T$, вообще говоря, скрытые переменные, которые мы ввели, чтобы постепенно генерировать изображения. Значит, мы получили модель с латентными переменными и хотим оптимизировать $\log p_\theta(x_0)$ (неполное правдоподобие). Для решения этой задачи мы можем оптимизировать ELBO:

$$\mathbb{E}_{q(x_0)} \log p_\theta(x_0) \geq \mathbb{E}_{q(x_0)} \int q(x_1, \dots, x_T \mid x_0) \log \frac{p_\theta(x_T, \dots, x_0)}{q(x_1, \dots, x_T \mid x_0)} dx_T \dots dx_1 =: L. \tag{14}$$

Воспользуемся тем, что процессы зашумления и генерации являются марковскими цепями:

$$\mathbb{E}_{q(x_0)} \int q(x_1, \dots, x_T \mid x_0) \log \frac{p(x_T) p_\theta(x_{T-1} \mid x_T) \cdot \ldots \cdot p_\theta(x_0 \mid x_1)}{q(x_1 \mid x_0) \cdot \ldots \cdot q(x_{T-1} \mid x_{T-2}) \cdot q(x_T \mid x_{T-1})} dx_T \dots dx_1. \tag{15}$$

Выше мы получили отношения вида $\frac{p_\theta(x_t \mid x_{t+1})}{q(x_t \mid x_{t-1})}$ для $t \in \{1, \dots, T-1\}$, что напоминает KL-дивергенции. Однако тогда мы не сможем добиться совпадения распределения $p_\theta(x_t \mid x_{t+1})$ с $q(x_t \mid x_{t-1})$, так как первое зависит от x_{t+1}, а второе от x_{t-1}. Для решения этой проблемы нам потребуется следующая лемма.

Лемма 1. *Если* $q(x_1, \dots, x_T \mid x_0) = \prod_{t=1}^T q(x_t \mid x_{t-1})$, *то* $q(x_t \mid x_{t+1}, \dots, x_T, x_0) = q(x_t \mid x_{t+1}, x_0)$, *то есть если мы развернём время и зафиксируем конечную точку, то это также будет марковской цепью.*

Доказательство:

Воспользуемся марковским свойством

$$q(x_t, \dots, x_T \mid x_0) = q(x_t \mid x_0) q(x_{t+1} \mid x_t) \dots q(x_T \mid x_{T-1}), \tag{16}$$

с другой стороны, по определению:

$$q(x_t, \dots, x_T \mid x_0) = q(x_t \mid x_{t+1}, \dots, x_T, x_0) q(x_{t+1}, \dots, x_T \mid x_0). \tag{17}$$

Из чего следует, что правые части равны, а значит

$$q(x_t \mid x_{t+1}, \dots, x_T, x_0) q(x_{t+1}, \dots, x_T \mid x_0) = q(x_t \mid x_0) q(x_{t+1} \mid x_t) \dots q(x_T \mid x_{T-1}). \tag{18}$$

Для того, чтобы прийти к $q(x_t \mid x_{t+1}, x_0)$, воспользуемся формулой Байеса:

$$q(x_t \mid x_{t+1}, x_0) = \frac{q(x_{t+1} \mid x_t, x_0) q(x_t \mid x_0)}{q(x_{t+1} \mid x_0)} = \frac{q(x_{t+1} \mid x_t) q(x_t \mid x_0)}{q(x_{t+1} \mid x_0)}, \tag{19}$$

мы заменили $q(x_{t+1} \mid x_t, x_0)$ на $q(x_{t+1} \mid x_t)$, так как это марковская цепь. Подставим выражение 19 в правую часть выражения 18:

$$q(x_t \mid x_{t+1}, \dots, x_T, x_0) q(x_{t+1}, \dots, x_T \mid x_0) = q(x_t \mid x_{t+1}, x_0) q(x_{t+1} \mid x_0) \dots q(x_T \mid x_{T-1}), \tag{20}$$

$$q(x_t \mid x_{t+1}, \dots, x_T, x_0) q(x_{t+1}, \dots, x_T \mid x_0) = q(x_t \mid x_{t+1}, x_0) q(x_{t+1}, \dots, x_T \mid x_0), \tag{21}$$

значит $q(x_t \mid x_{t+1}, \dots, x_T, x_0) = q(x_t \mid x_{t+1}, x_0)$.

Из Леммы 1 следует

$$q(x_1, \dots, x_T \mid x_0) = q(x_T \mid x_0) \prod_{t=1}^{T-1} q(x_t \mid x_{t+1}, x_0), \tag{22}$$

подставим полученную факторизацию в ELBO:

$$L = \mathbb{E}_{q(x_0)} \int q(x_1, \dots, x_T \mid x_0) \log \frac{p_\theta(x_T, \dots, x_0)}{q(x_1, \dots, x_T \mid x_0)} dx_T \dots dx_1 = \tag{23}$$

$$= \mathbb{E}_{q(x_0)} \int q(x_1, \dots, x_T \mid x_0) \log \frac{p(x_T) p_\theta(x_{T-1} \mid x_T) \cdot \dots \cdot p_\theta(x_0 \mid x_1)}{q(x_1 \mid x_2, x_0) \cdot \dots \cdot q(x_T \mid x_0)} dx_T \dots dx_1. \tag{24}$$

Разобьём выражение внутри логарифма на слагаемые так, чтобы из него получить распределения на одни и те же переменные:

$$\mathbb{E}_{q(x_0)} \underbrace{\int q(x_1, \dots, x_T \mid x_0) \log p_\theta(x_0 \mid x_1) dx_T \dots dx_1}_{L_0} + \tag{25}$$

$$+ \sum_{t=1}^{T-1} \mathbb{E}_{q(x_0)} \underbrace{\int q(x_1, \dots, x_T \mid x_0) \log \frac{p_\theta(x_t \mid x_{t+1})}{q(x_t \mid x_{t+1}, x_0)} dx_T \dots dx_1}_{L_t} + \tag{26}$$

$$+ \mathbb{E}_{q(x_0)} \underbrace{\int q(x_1, \dots, x_T \mid x_0) \log \frac{p(x_T)}{q(x_T \mid x_0)} dx_T \dots dx_1}_{L_T}. \tag{27}$$

Обратим внимание, что L_T не зависит от θ, а значит, мы можем не учитывать его при оптимизации; $p_\theta(x_0 \mid x_1)$ в статье предлагается зафиксировать как заранее заданное нормальное распределение (подробнее в Секции 3.3 статьи DDPM). Подробнее рассмотрим L_t при $t \in \{1, \dots, T-1\}$ и попробуем выделить KL-дивергенцию. Напомним, что $D_{\mathrm{KL}}(q(x) \parallel p(x)) := \int q(x) \log \frac{q(x)}{p(x)} dx$. Для этого нам потребуется из $q(x_1, \dots, x_T \mid x_0)$ отделить $q(x_t \mid x_{t+1}, x_0)$. Для этого два раза воспользуемся определением условной вероятности:

$$q(x_1, \dots, x_T \mid x_0) = q(x_{1:T}^{\setminus t, t+1} \mid x_t, x_{t+1}, x_0) q(x_t, x_{t+1} \mid x_0) = \tag{28}$$

$$= q(x_{1:T}^{\setminus t, t+1} \mid x_t, x_{t+1}, x_0) q(x_t \mid x_{t+1}, x_0) q(x_{t+1} \mid x_0), \tag{29}$$

где $x_{1:T}^{\setminus t, t+1}$ значит $x_1, \dots x_{t-1}, x_{t+2}, \dots x_T$.

Подставим полученное разложение в L_t.

$$L_t = \int q(x_1, \dots, x_T \mid x_0) \log \frac{p_\theta(x_t \mid x_{t+1})}{q(x_t \mid x_{t+1}, x_0)} dx_T \dots dx_1 = \tag{30}$$

$$= - \int q(x_{1:T}^{\setminus t, t+1} \mid x_t, x_{t+1}, x_0) q(x_t \mid x_{t+1}, x_0) q(x_{t+1} \mid x_0) \log \frac{q(x_t \mid x_{t+1}, x_0)}{p_\theta(x_t \mid x_{t+1})} dx_T \dots dx_1 = \tag{31}$$

$$= - \int q(x_{1:T}^{\setminus t, t+1} \mid x_t, x_{t+1}, x_0) q(x_{t+1} \mid x_0) q(x_t \mid x_{t+1}, x_0) \log \frac{q(x_t \mid x_{t+1}, x_0)}{p_\theta(x_t \mid x_{t+1})} dx_T \dots dx_1. \tag{32}$$

Нам бы хотелось упростить интегральное выражение. Мы можем рассмотреть кратный интеграл как повторный:

$$\int q(x_{t+1} \mid x_0) q(x_t \mid x_{t+1}, x_0) \log \frac{q(x_t \mid x_{t+1}, x_0)}{p_\theta(x_t \mid x_{t+1})} \underbrace{\int q(x_{1:T}^{\setminus t,t+1} \mid x_t, x_{t+1}, x_0) dx_{T:1}^{\setminus t,t+1}}_{=1} dx_{t:t+1} = \tag{33}$$

$$= \int q(x_{t+1} \mid x_0) \int q(x_t \mid x_{t+1}, x_0) \log \frac{q(x_t \mid x_{t+1}, x_0)}{p_\theta(x_t \mid x_{t+1})} dx_t dx_{t+1} = \tag{34}$$

$$= \int q(x_{t+1} \mid x_0) D_{\mathrm{KL}}(q(x_t \mid x_{t+1}, x_0) \parallel p_\theta(x_t \mid x_{t+1})) \, dx_{t+1} = -L_t \tag{35}$$

где $dx_{T:1}^{\setminus t,t+1} \coloneqq dx_T \dots dx_{t+2} dx_{t-1} \dots dx_1$. Получается, исходная задача максимизации ELBO по θ эквивалентна задаче

$$\text{const} - \sum_{t=1}^{T-1} \mathbb{E}_{q(x_0)} \mathbb{E}_{q(x_{t+1} \mid x_0)} D_{\mathrm{KL}}(q(x_t \mid x_{t+1}, x_0) \parallel p_\theta(x_t \mid x_{t+1})) \to \max_\theta, \tag{36}$$

$$\sum_{t=1}^{T-1} \mathbb{E}_{q(x_0)} \mathbb{E}_{q(x_{t+1} \mid x_0)} D_{\mathrm{KL}}(q(x_t \mid x_{t+1}, x_0) \parallel p_\theta(x_t \mid x_{t+1})) \to \min_\theta. \tag{37}$$

Примечание: Для вывода обучения можно сделать следующую цепочку рассуждений: мы бы хотели, чтобы процесс генерации имел те же распределения, что и процесс зашумления, следовательно, нам нужно оптимизировать KL-дивергенцию между ними. Этот подход, возможно, проще для вывода, так как не требует знания ELBO и он приводит к тому же результату. Мы рассмотрели способ через ELBO, так как следуем статье DDPM.

5.5 Параметризация диффузионной модели

Мы получили задачу оптимизации суммы математических ожиданий KL-дивергенций. Мы знаем, что минимум KL-дивергенции достигается при равенстве двух распределений почти всюду. Для фиксированного x_0 KL-дивергенция минимальна, когда $p_\theta(x_t \mid x_{t+1}) \coloneqq q(x_t \mid x_{t+1}, x_0)$. Поскольку $p_\theta(x_t \mid x_{t+1})$ не зависит от x_0, то мы её параметризуем через предсказание x_0, разберём подробнее.

Мы знаем, что $q(x_t \mid x_{t+1}, x_0) = \frac{q(x_{t+1} \mid x_t, x_0) q(x_t \mid x_0)}{q(x_{t+1} \mid x_0)} = \frac{q(x_{t+1} \mid x_t) q(x_t \mid x_0)}{q(x_{t+1} \mid x_0)}$. Все распределения в правой части нормальные, а значит, $q(x_t \mid x_{t+1}, x_0)$ тоже нормальное распределение[2]. Кроме того, мы можем посчитать, чему равны его параметры:

$$q(x_t \mid x_{t+1}, x_0) = \mathcal{N}\left(x_t \mid \tilde{\mu}(x_{t+1}, x_0), \tilde{\beta}_{t+1} \mathbf{I}\right), \tag{38}$$

$$\tilde{\mu}(x_{t+1}, x_0) \coloneqq \frac{\sqrt{\bar{\alpha}_t} \beta_{t+1}}{1 - \bar{\alpha}_{t+1}} x_0 + \frac{\sqrt{1 - \beta_{t+1}}(1 - \bar{\alpha}_t)}{1 - \bar{\alpha}_{t+1}} x_{t+1}, \tag{39}$$

$$\tilde{\beta}_{t+1} \coloneqq \frac{1 - \bar{\alpha}_t}{1 - \bar{\alpha}_{t+1}} \beta_{t+1}. \tag{40}$$

Значит, $p_\theta(x_t \mid x_{t+1})$ должно быть тоже нормальным распределением. Возьмём

$$p_\theta(x_t \mid x_{t+1}) \coloneqq q(x_t \mid x_{t+1}, x_\theta(x_{t+1}, t+1)), \tag{41}$$

где $x_\theta(x_{t+1}, t+1)$ — нейронная сеть с параметрами θ, тогда мы можем посчитать KL-дивергенцию между двумя нормальными распределениями:

$$D_{\mathrm{KL}}(q(x_t \mid x_{t+1}, x_0) \parallel p_\theta(x_t \mid x_{t+1})) = C_{t+1} \|\tilde{\mu}(x_{t+1}, x_0) - \tilde{\mu}(x_{t+1}, x_\theta(x_{t+1}, t+1))\|^2 = \tag{42}$$

$$= C'_{t+1} \|x_0 - x_\theta(x_{t+1}, t+1)\|^2, \tag{43}$$

где C_{t+1} и C'_{t+1} можно посчитать аналитически[3].

[2] Похожее мы делали в лекции на байесовскую линейную регрессию.

[3] Дисперсию мы можем посчитать аналитически, так как она не зависит от x_0.

Мы получили, что задача оптимизации ELBO эквивалентна задаче

$$\sum_{t=1}^{T-1} \mathbb{E}_{q(x_0)}\, \mathbb{E}_{q(x_{t+1}\,|\,x_0)}\, C'_{t+1} \|x_0 - x_\theta(x_{t+1}, t+1)\|^2 \to \min_\theta . \tag{44}$$

Нейронную сеть $x_\theta(\cdot, \cdot)$ часто называют денойзером. С другой стороны:

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1-\bar{\alpha}_t}\varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \mathbf{I}), \tag{45}$$

$$x_0 = \frac{x_t - \sqrt{1-\bar{\alpha}_t}\varepsilon}{\sqrt{\bar{\alpha}_t}}, \tag{46}$$

а значит, что $x_\theta(x_t, t) = \frac{x_t - \sqrt{1-\bar{\alpha}_t}\varepsilon_\theta(x_t, t)}{\sqrt{\bar{\alpha}_t}}$. Тогда задача эквивалентна:

$$\sum_{t=1}^{T-1} \mathbb{E}_{q(x_0)}\, \mathbb{E}_{q(x_{t+1}\,|\,x_0)}\, C''_{t+1} \|\varepsilon - \varepsilon_\theta(x_{t+1}, t+1)\|^2 \to \min_\theta . \tag{47}$$

В DDPM рассматривают именно параметризацию ε_θ. Заметим, что мы можем оптимизировать функционал с помощью Монте-Карло. Для оценки суммы мы можем выбрать одно слагаемое, для математического ожидания мы можем взять сэмпл x_0 из датасета $\mathcal{D}$, а x_t получить из $q(x_t \,|\, x_0) = \mathcal{N}\left(x_t \mid \sqrt{\bar{\alpha}_t} x_0, (1-\bar{\alpha}_t)\mathbf{I}\right)$. Нам не нужно прогонять всю марковскую цепь для получения x_t. Этот подход называется simulation-free.

Кроме того, авторы статьи DDPM заметили, что если отбросить коэффициент C''_{t+1}, то можно улучшить метрику качества. Полученную функцию потерь называют L_{simple}. Обучение представлено в Алгоритме 1[4].

Для генерации нам нужно будет сделать T шагов, то есть T раз вычислить значение нейронной сети. Подробно генерация расписана в Алгоритме 2.

Algorithm 1 Обучение

repeat
  $x_0 \sim \mathcal{D}$
  $t \sim \text{Uniform}(\{1, \dots, T\})$
  $\epsilon \sim \mathcal{N}(0, \mathbf{I})$
  $x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon$
  $L_{\text{simple}} \coloneqq \|\varepsilon - \varepsilon_\theta(x_t, t)\|^2$
  L_{simple}.backward()
until converged

Algorithm 2 Сэмплирование

$x_T \sim \mathcal{N}(0, \mathbf{I})$
for $t = T, \dots, 1$ **do**
  $z \sim \mathcal{N}(0, \mathbf{I})$ if $t > 1$, else $z = 0$
  $x_{t-1} = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}}\varepsilon_\theta(x_t, t)\right) + \sqrt{\tilde{\beta}_t} z$
end for
return x_0

5.6 Метрика качества

Если мы уже обучили модель, то возникает вопрос: как получить объективную метрику качества модели. Один из вариантов получения объективной оценки — ответить на вопрос: насколько распределение генерируемых моделью изображений «похоже» на распределение истинных изображений.

Таким образом, мы свели задачу объективной оценки к нахождению схожести между распределениями.

Существует множество способов оценки схожести распределений. В области computer vision популярным способом является **FID (Fréchet Inception Distance)**. Данная метрика вычисляет квадрат *расстояния Вассерштейна*-2 между распределениями активаций некоторой обученной свёрточной модели.

Подробнее смотрите в статье GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium.

[4] Обратите внимание, что в L_{simple} учитывается $t = 1$, так как в статье предлагается зафиксировать $p_\theta(x_0 \,|\, x_1) = \mathcal{N}\left(x_0 \mid \tilde{\mu}(x_1, x_\theta(x_1, 1)), \beta_1 \mathbf{I}\right)$, подробнее в Секции 3.3.

Более конкретно, положим, что есть два множества изображений, которые мы хотим сравнить:

$$A = \{a_i\}, B = \{b_j\}, \quad a_i, b_i \in \mathcal{I}. \tag{48}$$

Рассмотрим глубокую свёрточную модель для извлечения векторных представлений:

$$M : \mathcal{I} \to \mathbb{R}^d. \tag{49}$$

Предположим, что

$$M(a) \sim \mathcal{N}(\mu_A, \Sigma_A), \tag{50}$$

$$M(b) \sim \mathcal{N}(\mu_B, \Sigma_B). \tag{51}$$

Предположение метрики FID утверждает, что если распределения $M(a)$, $M(b)$ близки друг к другу, то и множества изображений A, B похожи. Данное утверждение было проверено эмпирически.

В качестве меры близости между распределениями используется *расстояние Вассерштейна*-2:

$$\textbf{FID} = \mathcal{W}_2^2(\mathcal{N}(\mu_A, \Sigma_A), \mathcal{N}(\mu_B, \Sigma_B)) = ||\mu_A - \mu_B||_2^2 + \mathrm{Tr}\Big(\Sigma_A + \Sigma_B - 2\sqrt{\Sigma_A \Sigma_B}\Big). \tag{52}$$

Стандартным выбором для модели выделения признаков M является **Inception V3**. В частности, берутся активации после Average Pooling, что даёт размерность признакового вектора $d = 2048$.

Для подсчёта метрик обычно фиксируют некоторое количество сгенерированных изображений. Типичный размер $|A| = 5000$ или 50000.